

Proyecto

Educación, acceso y desempeño académico

Etapas 3 - Limpieza SSIS

Oscar Giovanni Robayo

Oscar Felipe Delgado

Facultad de Ingeniería

Programa de Ingeniería de Sistemas y Computación

Universidad de Cundinamarca, Extensión Chía

Minería De Datos

Chía, Cundinamarca

Septiembre 2026

2. Introducción

El análisis de la calidad de los datos es un pilar fundamental en el proyecto «Educación, acceso y desempeño académico», ya que la presencia de información sesgada o inconsistente compromete la fiabilidad de los modelos de minería de datos y de las políticas públicas asociadas. Para superar las deficiencias diagnosticadas en etapas previas, este informe técnico documenta la implementación y verificación de un proceso ETL automatizado mediante SQL Server Integration Services (SSIS). A través de tres iteraciones controladas, el pipeline aplica reglas de tratamiento para corregir anomalías, manejar valores nulos y estandarizar formatos, conservando una zona de staging y una tabla de auditoría para garantizar la trazabilidad. Finalmente, el proceso asegura la idempotencia ante la repetición de lotes y se integra de forma dinámica en la aplicación web del proyecto desarrollada en Flask y alojada en Render.

3. Objetivo de la Etapa

Implementar y verificar un proceso ETL mediante SQL Server Integration Services (SSIS) para tratar de manera sistemática los problemas de calidad de datos identificados en la etapa anterior del proyecto. Para ello, se deben llevar a cabo tres iteraciones del tratamiento, documentar detalladamente los ajustes y resultados, garantizar la idempotencia ante la repetición de lotes, y publicar tanto el informe técnico paso a paso como el video de demostración en la aplicación web del proyecto en Flask.

1. Diagnóstico inicial y reglas de tratamiento definidas.


Campo Afectado	Acción de Tratamiento (SSIS)	Justificación Técnica
estu_grado	Exclusión Condicional (Filtro). Enrutamiento de registros con valor > 11 hacia tabla de auditoría.	Presenta valores atípicos absurdos (ej. 20234.0) por errores de concatenación en origen. Se aíslan para no sesgar el entrenamiento del modelo.
cole_area_ubicacion_oficial	Homologación (Cruce Geográfico). Enriquecimiento de datos cruzando la llave cole_codigo_icfes contra la dimensión limpia del DUE.	La variable original presentaba 14.17% de nulos. Se rescata la ubicación real directamente desde el Directorio Único de Establecimientos.
Variables de Texto (nombres, municipios, zonas)	Conversión de Tipo de Dato. Transformación de codificación UTF-8 a texto Unicode (DT_WSTR).	Prevenir conflictos de página de códigos (Code Page Mismatch 65001 vs 1252) y pérdida de caracteres especiales (tildes/eñes) detectados en el volcado a Staging.
fami_tieneinternet (y relativas a TIC)	Conservación con Imputación. Mantenimiento del atributo a pesar de su índice de valores nulos (~20%).	Dada la naturaleza de autorreporte, su eliminación (Drop) sesgaría la muestra destruyendo representatividad rural. Se tratará en el modelado (imputación o categoría "No Informa").

2. Diseño y Explicación del Control Flow y Data Flow

La arquitectura del paquete SSIS se estructuró para garantizar la integridad referencial y el aislamiento de errores, separando la carga de dimensiones paramétricas del procesamiento intensivo de la tabla principal (Saber 11).


A. Flujo de Control (Control Flow) El lienzo principal orquesta la ejecución secuencial de tres tareas fundamentales para mantener la idempotencia del ETL:

1. **SQL_LimpiarTablas_Staging (Execute SQL Task):** Ejecuta un script de truncado (*TRUNCATE TABLE*) sobre las tablas de destino en *EduMetrics_Staging* (*Dim_Directorio_DUE*, *Staging_Saber11*, *Errores_Saber11_Auditoria*). Esto previene violaciones de llave primaria (PK) al ejecutar múltiples iteraciones.
2. **DFT_Carga_Directorio_DUE (Data Flow Task):** Ingesta la dimensión geográfica previamente estandarizada con Python. Su ejecución exitosa es un prerequisite estricto (precedencia verde) para el flujo principal.
3. **DFT_Limpieza_Saber11 (Data Flow Task):** Procesa la muestra de 1 millón de registros, ejecutando las reglas de validación, filtrado y enriquecimiento.




B. Flujo de Datos 1: Dimensión DUE (DFT_Carga_Directorio_DUE)

- **Origen (Flat File Source):** Lee el archivo *Dim_DUE_Limpio.csv*. Configurado con *Code Page 65001 (UTF-8)* y tipificación nativa de la llave primaria *codigoestablecimiento* como entero largo (*DT_I8*).
- **Conversión de Datos:** Castea las variables de texto (*zona*, *nombreestablecimiento*, *municipio*) a cadenas Unicode (*DT_WSTR*) para emparejarse con las columnas *NVARCHAR* del motor de base de datos, neutralizando el *mojibake*.
- **Destino (OLE DB Destination):** Inserta la dimensión limpia en SQL Server.



C. Flujo de Datos 2: Transformación Principal (DFT_Limpieza_Saber11)

- **Origen:** Extracción de la muestra aleatoria de Saber 11 (*Code Page 65001*).
- **Bifurcación (CS_Filtro_Anomalias - Conditional Split):** Aplica la regla de negocio *estu_grado <= 11*. Separa físicamente el flujo en dos:
 - *Ruta de Éxito (Registros_Validos):* Continúa hacia el enriquecimiento.
 - *Ruta de Error (Registros_Con_Errores):* Desvía los outliers (ej. 20234.0) directamente hacia la tabla *Errores_Saber11_Auditoria*.
- **Cruce Geográfico (LKP_Directorio_DUE - Lookup):** Configurado en modo *Ignore failure* (comportamiento *LEFT JOIN*). Cruza *cole_codigo_icfes* contra la base de datos para rescatar la variable homologada *cole_area_ubicacion_oficial*.
- **Destino Final:** Volcado de los datos curados a *Staging_Saber11*.




3. Configuración Paso a Paso de los Componentes en SSIS

La transformación de los microdatos se ejecutó utilizando componentes nativos de Integration Services para garantizar la limpieza sin depender de scripts externos en tiempo de ejecución. A continuación, se detalla la configuración y función de cada componente clave dentro del *DFT_Limpieza_Saber11* y *DFT_Carga_Directorio_DUE*:


A. Administradores de Conexión y Orígenes de Datos (Flat File Source)

- **Función:** Extraer los datos desde los archivos planos CSV (*saber11_muestra_1M.csv* y *Dim_DUE_Limpio.csv*).
- **Configuración Aplicada:** Se modificó la propiedad **Code page** a *65001 (UTF-8)* en la pestaña *General* para preservar la ortografía original de los municipios (tildes y eñes). En la pestaña *Advanced*, las llaves primarias y códigos numéricos (ej. *codigoestablecimiento*) se tipificaron explícitamente como Enteros Largos (*eight-byte signed integer [DT_I8]*) para prevenir errores de casteo y pérdida de datos en vuelo.




B. Data Conversion (Conversión de Datos)

- **Función:** Neutralizar los conflictos de arquitectura generados por la mezcla de páginas de códigos (1252 vs 65001) y preparar las cadenas de texto para su inserción en bases de datos.
- **Configuración Aplicada:** Las variables descriptivas (*zona*, *nombreestablecimiento*, *municipio* y atributos del estudiante) se seleccionaron en la grilla y su **Data Type** se configuró estrictamente como *Unicode string [DT_WSTR]*. Esto homologa el flujo hacia las columnas *NVARCHAR* de SQL Server, eliminando el error de *cannot convert between unicode and non-unicode*.




C. Conditional Split (División Condicional: CS_Filtro_Anomalias)

- **Función:** Evaluar la validez lógica de los registros y bifurcar el flujo de datos para separar los valores atípicos del dataset limpio, cumpliendo con la regla de negocio del grado escolar.
- **Configuración Aplicada:** Se creó una salida principal denominada *Registros_Validos* con la expresión condicional *estu_grado <= 11*. La salida predeterminada del componente se renombró a *Registros_Con_Errores*. Esto aísla matemáticamente los 446,405 outliers (valores como 20234.0) sin detener la ejecución del paquete.




D. Lookup (Búsqueda: LKP_Directorio_DUE)


- **Función:** Realizar una homologación espacial mediante un cruce referencial para rescatar el área de ubicación oficial del colegio desde la dimensión pre-limpiada.
- **Configuración Aplicada:**
 - *General:* Se configuró la directiva *Specify how to handle rows with no matching entries* en **Ignore failure**. Esto fuerza un comportamiento de *LEFT JOIN*, evitando el colapso del pipeline si un colegio no existe en el DUE.
 - *Columns:* Se mapeó la columna de entrada *cole_codigo_icfes* contra la columna de búsqueda *cole_codigo_icfes*, seleccionando *cole_area_ubicacion_oficial* como nueva columna de salida.



E. OLE DB Destination (Destinos en Staging)

- **Función:** Persistir los datos transformados en el Data Warehouse temporal (*EduMetrics_Staging*).
- **Configuración Aplicada:** En la pestaña *Mappings*, se enlazaron las columnas derivadas (*Copy of...*) y las salidas del Lookup hacia las columnas *NVARCHAR* y *BIGINT* de las tablas *Staging_Saber11* y *Errores_Saber11_Auditoria*. Se habilitó la carga rápida (*Table or view - fast load*) para optimizar la inserción del millón de registros.





The screenshot displays the SQL Server Data Tools (SSDT) interface. On the left, a data flow diagram shows a sequence of tasks: **DC_Inputar_Nulos** (Data Conversion Task) feeds into **CS_Filtro_Anomalias** (Data Flow Task), which then feeds into **Registros_Con_Errores** (Data Flow Task), followed by **DC_Motivo_Error** (Data Conversion Task), and finally **Destino_Errores_Auditoria** (OLE DB Destination Task). The **Destino_Errores_Auditoria** task is highlighted with a blue border.

On the right, the **OLE DB Destination Editor** window is open, titled "Configure the properties used to insert data into a relational database using an OLE DB provider." The window has three tabs: **Connection Manager** (selected), **Mappings**, and **Error Output**.

The **Connection Manager** tab contains the following configuration:

- OLE DB connection manager:** A dropdown menu showing **OLEDB_Staging** with a **New...** button.
- Data access mode:** A dropdown menu showing **Table or view - fast load**.
- Name of the table or the view:** A dropdown menu showing **[dbo].[Saber11_Errores_Auditoria]** with a **New...** button.
- Keep identity:** An unchecked checkbox.
- Table lock:** A checked checkbox.

4. Evidencias de Ejecución (Tres Iteraciones) y Manejo de Errores

El proceso ETL se estabilizó a través de tres iteraciones de ejecución y ajuste en SSIS, documentando el comportamiento del flujo ante el volumen de datos y los conflictos de calidad.

A. Estrategia de Manejo de Errores y Revisiones

Los registros que no superaron las reglas de calidad (específicamente la validación *estu_grado <= 11*) no interrumpieron el flujo de datos. Mediante la salida predeterminada del *Conditional Split*, fueron enrutados físicamente hacia la tabla *Errores_Saber11_Auditoria* en SQL Server. Se conservó el valor original (ej. 20234.0) junto con un código de motivo y la fecha de ejecución, garantizando la trazabilidad sin contaminar el modelo final.


B. Registro de Iteraciones


Iteración	Ajustes Aplicados	Resultados y Hallazgos
Iteración 1	Ejecución inicial del Data Flow conectando el CSV plano directamente hacia Staging.	Fallo: Colapso del pipeline por <i>Code Page Mismatch</i> (65001 vs 1252) y truncamiento en la dimensión DUE por categorías atípicas (<i>URBANARURAL</i>).
Iteración 2	Preprocesamiento del DUE con Python. Configuración nativa de orígenes a <i>DT_I8</i> y conversión de textos a Unicode (<i>DT_WSTR</i>).	Éxito Parcial: El flujo compiló, los acentos/tildes se visualizaron correctamente y el Lookup geográfico operó sin fallas. Se identificó la población anómala en la variable grados.
Iteración 3	Implementación del filtro <i>Conditional Split</i> y ejecución completa del flujo sobre el lote	Éxito Total: Separación efectiva de la población válida y la anómala. Cero duplicados generados gracias al truncado previo de la tarea SQL.

Iteración	Ajustes Aplicados	Resultados y Hallazgos
	de 1.000.000 de registros con limpieza previa.	

C. Consolidado Final de Registros (Iteración 3)

- **Total de Registros Recibidos (Origen): 1,000,000**
- **Registros Aceptados (Staging_Saber11): 761.173**
- **Registros Enviados a Revisión (Errores_Saber11_Auditoria): 238.827**
- **Registros Duplicados Generados: 0**





The screenshot shows a SQL Server Enterprise Manager interface with three queries executed. The first query counts records in Dim_Directorio_DUE (22530), the second counts records in Saber11_Errores_Auditoria (238381), and the third counts records in Saber11_Tratado (761173). The results are displayed in a table format with a single column labeled '(No column name)' and a single row for each query.

```
SQLQuery2.sql...O\ingor (54))* SQLQuery1.sql...O\ingor (64))*  
1 select count (*) from Dim_Directorio_DUE;  
2  
3 select count (*) from Saber11_Errores_Auditoria;  
4  
5 select count (*) from Saber11_Tratado  
6  
99 % No issues found  
Results Messages  
(No column name)  
1 22530  
(No column name)  
1 238381  
(No column name)  
1 761173
```

Prueba de Idempotencia (Repetición del Lote): Al ejecutar el paquete por cuarta vez sin alterar los archivos de origen, la tarea SQL_LimpiarTablas_Staging vació exitosamente las tablas antes del volcado. El conteo final se mantuvo exactamente en 761.173 registros aceptados, demostrando que **volver a ejecutar el mismo lote no genera duplicación de datos.**

5. Comparación de Resultados e Indicadores de Calidad (Antes y Después)

La aplicación del pipeline de transformación en SSIS sobre la muestra inicial de 1,000,000 de registros permitió mitigar los riesgos de validez y consistencia detectados en la Etapa 2. A continuación, se detalla la evolución de los indicadores de calidad:

A. Mejora en la Completitud y Estandarización Geográfica

- **Antes:** La variable *cole_area_ubicacion* (crucial para medir el impacto urbano vs. rural) presentaba un 14.17% de valores nulos o no estandarizados en la extracción original del ICFES.
- **Después:** Tras implementar el cruce mediante el componente *Lookup (LEFT JOIN* geográfico) contra la dimensión curada del DUE, se logró enriquecer la información. Los registros conservados en Staging cuentan ahora con una clasificación robusta respaldada por el directorio del Ministerio de Educación.

B. Aumento en la Validez Matemática (Filtro de Anomalías)

- **Antes:** La variable *estu_grado* contenía valores lógicamente imposibles para la educación media (ej. 20234.0, -9), contaminando el 9.8% del volumen total de la base.
- **Después:** La ejecución del *Conditional Split* (*estu_grado* <= 11) aisló perfectamente la población objetivo, garantizando un 100% de validez empírica en los datos que ingresarán a los modelos de *Machine Learning*.

C. Comparativa Volumétrica Final (Iteración 3)

Métrica / Estado	Valor Final
Volumen Inicial Extraído (Muestra)	1,000,000
Registros Válidos Aceptados (Staging_Saber11)	761,173
Registros Enviados a Revisión (Errores_Auditoria)	238,827
Dimensión DUE Estandarizada (Dim_Directorio_DUE)	22,530
Pérdida Injustificada de Datos (Fugas)	0%
Duplicidad por Reprocesamiento	0% (Idempotencia garantizada)

15. Referencias Bibliográficas

Batini, C., & Scannapieco, M. (2016). *Data and information quality: Dimensions, principles and techniques*. Springer.

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). John Wiley & Sons.

Microsoft. (2024). *Integration Services (SSIS) concepts and architecture*. Microsoft Learn. Recuperado de <https://learn.microsoft.com/sql/integration-services/>

Instituto Colombiano para la Evaluación de la Educación [ICFES]. (2023). *Bases de datos abiertas de las pruebas Saber 11 (2019–2023)*. Ministerio de Educación Nacional.

15. Enlaces del Proyecto

- URL del repositorio público en GitHub:
https://github.com/Rockbayo/MD_Proyecto_Educacion.git
- URL de la rama de desarrollo:
https://github.com/Rockbayo/MD_Proyecto_Educacion/tree/feature/etapa-3
- URL del Pull Request:
https://github.com/Rockbayo/MD_Proyecto_Educacion/pull/20
- URL de la aplicación Flask publicada:
<https://md-proyecto-educacion.onrender.com/>
- URL Video
<https://youtu.be/uQEiZYC2TV0>