Proyecto

Educación, acceso y desempeño académico

Semana 10

Etapa 4

Conocimiento Evidente

Oscar Giovanni Robayo

Oscar Felipe Delgado

Facultad de Ingeniería

Programa de Ingeniería de Sistemas y Computación

Universidad de Cundinamarca, Extensión Chía

Minería De Datos

Chía, Cundinamarca

Octubre 2026

2. Introducción

El análisis de la calidad de los datos y el posterior descubrimiento de conocimiento constituyen pilares fundamentales en el proyecto «Educación, acceso y desempeño académico». Tras la ejecución del proceso ETL automatizado e idempotente mediante SQL Server Integration Services (SSIS), el cual permitió tratar anomalías y estructurar una base limpia de 761,173 registros en Staging, la presente etapa se enfoca en el descubrimiento de conocimiento evidente. Mediante indicadores estadísticos, comparaciones territoriales y visualizaciones interactivas integradas en tableros de Power BI y en la aplicación web del proyecto en Flask, este informe documenta los patrones de la brecha digital y su repercusión en las pruebas Saber 11 en Colombia.

3. Objetivo de la Etapa

Implementar y verificar un análisis exploratorio avanzado sobre el conjunto de datos curado del ICFES (periodo 2019–2023), estructurando cuatro tableros analíticos en Power BI que respondan a preguntas específicas sobre composición poblacional, comparaciones territoriales, comportamiento temporal y análisis multivariado, documentando rigurosamente doce conocimientos evidentes y publicando la solución en la aplicación web del proyecto.

4. Unidad de Análisis, Cantidad de Registros y Variables Utilizadas

- **Unidad de Análisis:** Cada registro individual representa la participación y el resultado académico de un estudiante evaluado en las pruebas de Estado Saber 11.
- **Volumen de Datos:** 761,173 registros limpios y validados (post-filtrado SSIS sobre la muestra maestra).
- **Variables Clave Utilizadas:**
    - *Rendimiento (Target):* punt_global, punt_matematicas, punt_ingles.
    - *Tecnológicas:* fami_tieneinternet, fami_tienecomputador.
    - *Sociodemográficas e Institucionales:* fami_estratovivienda, fami_educacionpadre, cole_area_ubicacion_oficial, cole_naturaleza, periodo.

5. Resumen del Tratamiento Previsto de los Datos (Etapa Previa)

- **Tratamientos Aplicados (SSIS):**
    1. *Filtro de Anomalías:* Aislamiento de valores atípicos en grados escolares (estu_grado > 11), enviando 238,827 registros a auditoría y reteniendo 761,173 registros válidos.
    2. *Homologación Geográfica:* Cruce referencial con el Directorio Único de Establecimientos (DUE) para enriquecer la ubicación oficial.
    3. *Estandarización de Codificación:* Conversión de esquemas de texto a Unicode (DT_WSTR UTF-8) para preservar tildes y eñes.

6. Cuatro Preguntas de Análisis y su Justificación

1. **Pregunta 1 (Composición y Población):** ¿Qué proporción de estudiantes evaluados cuenta con acceso a internet en sus hogares y cómo se distribuye según el nivel socioeconómico?
2. **Pregunta 2 (Comparación Territorial):** ¿Existe una diferencia empírica en el desempeño global y la penetración tecnológica entre las instituciones urbanas y rurales?
3. **Pregunta 3 (Comportamiento Temporal):** ¿Cómo evolucionaron el rendimiento académico global y la tenencia de hardware durante el periodo de la pandemia (2019–2023)?
4. **Pregunta 4 (Análisis Multivariado):** ¿De qué manera la combinación conjunta entre la educación de los padres, la tenencia de computador y la naturaleza del colegio condiciona el puntaje global?

7. Descripción del Modelo de Datos en Power BI

El modelo relacional en Power BI utiliza un esquema en estrella con una tabla central de hechos (Saber11_Tratado) y dimensiones asociadas (Tiempo, Ubicación, Institución, Estudiante) mediante relaciones de $1:N$, garantizando la integridad en los cálculos DAX sin duplicación de métricas.

8. Procedimientos y Medidas DAX Principales

- **Total Evaluados:** Total_Evaluados = COUNTROWS(Saber11_Tratado)
- **Promedio Global:** Promedio_Global = AVERAGE(Saber11_Tratado[punt_global])
- **Porcentaje con Internet:** _Con_Internet =
  DIVIDE(CALCULATE(COUNTROWS(Saber11_Tratado),
  Saber11_Tratado[fami_tieneinternet] == "SI"),
  CALCULATE(COUNTROWS(Saber11_Tratado),
  NOT(ISBLANK(Saber11_Tratado[fami_tieneinternet])))) * 100

9. Evidencias de los Cuatro Tableros y Enunciados Desglosados por Gráfico

Tablero 1: Demografía, Estratos y Conectividad

- **Enunciado General del Tablero:** Análisis de la disponibilidad de herramientas tecnológicas de conectividad e informática en los hogares de los evaluados frente a su estratificación socioeconómica.

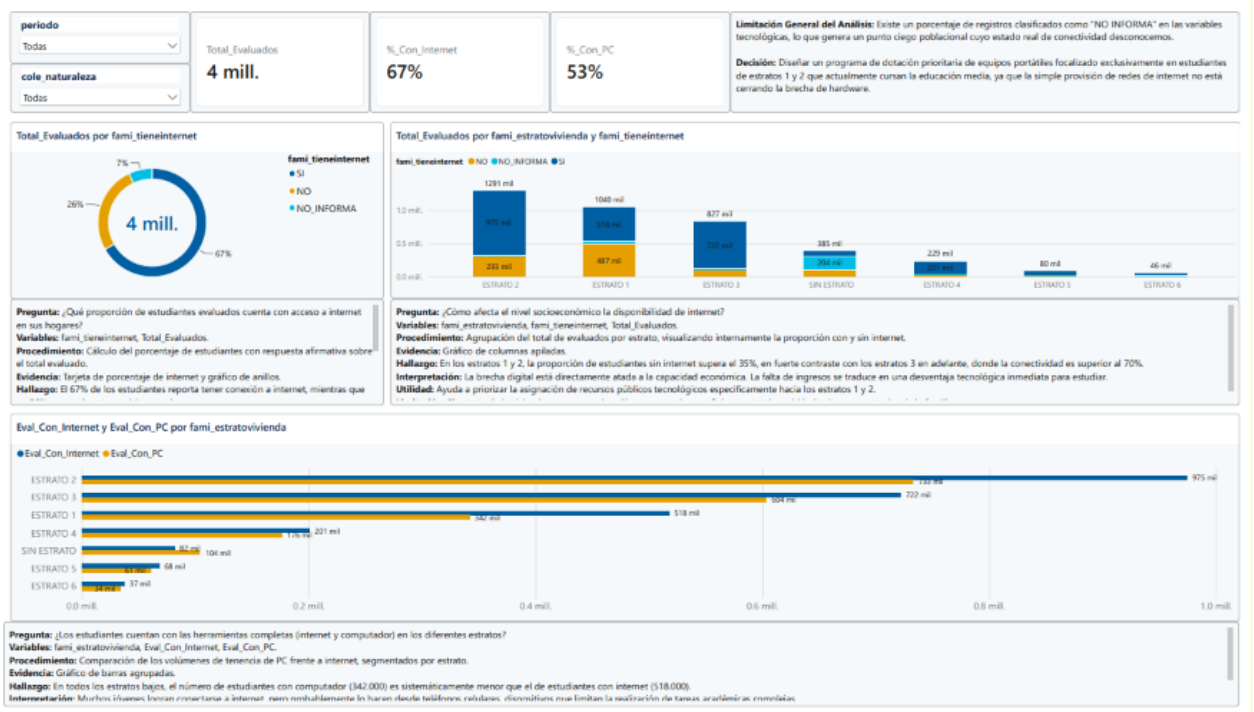
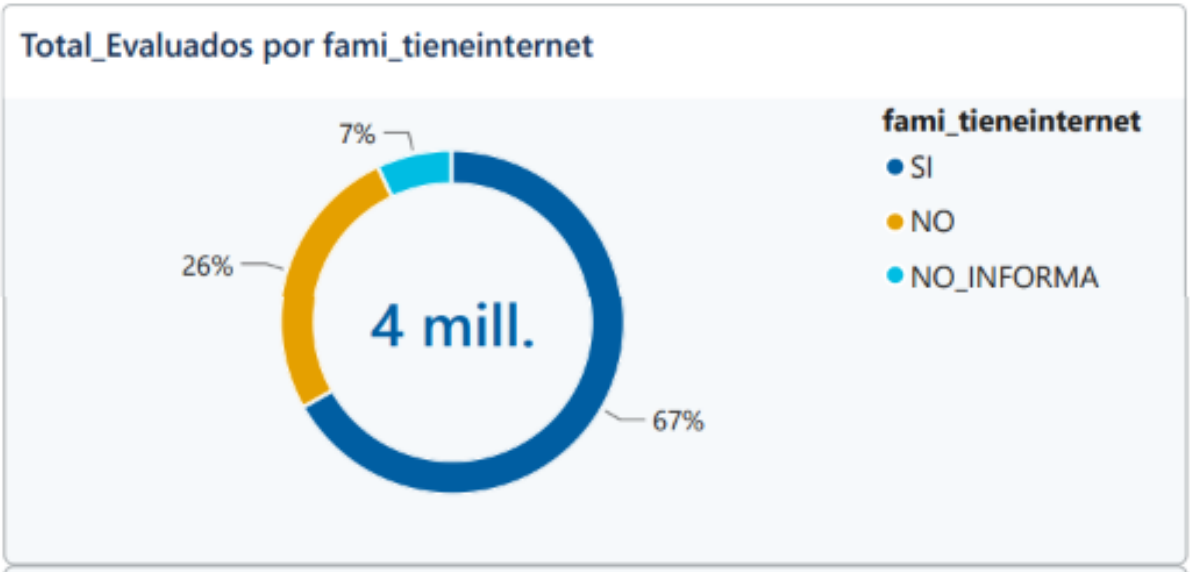


Gráfico 1.1: Recuento de Evaluados por Tenencia de Internet

- **Tipo de Gráfico:** Gráfico de Anillos y Tarjeta KPI.
- **Pregunta:** ¿Qué proporción de estudiantes evaluados cuenta con acceso a internet en sus hogares?
- **Variables:** fami_tieneinternet, Total_Evaluados.
- **Procedimiento:** Cálculo porcentual de respuestas afirmativas, negativas y sin información sobre el total de la muestra.
- **Evidencia:** Tarjeta de porcentaje y diagrama de anillos.

- **Hallazgo:** El 67% de los estudiantes reporta contar con conexión a internet, un 26% carece del servicio y un 7% no informa.
- **Interpretación:** Un tercio de la población estudiantil opera con limitaciones severas de conectividad fija en casa.
- **Utilidad:** Dimensiona la magnitud poblacional afectada por la brecha digital inicial.
- **Limitación:** Corresponde a autorreporte en la inscripción sin validación de velocidad.



Pregunta: ¿Qué proporción de estudiantes evaluados cuenta con acceso a internet en sus hogares?
Variables: fami_tieneinternet, Total_Evaluados.
Procedimiento: Cálculo del porcentaje de estudiantes con respuesta afirmativa sobre el total evaluado.
Evidencia: Tarjeta de porcentaje de internet y gráfico de anillos.
Hallazgo: El 67% de los estudiantes reporta tener conexión a internet, mientras que

Gráfico 1.2: Distribución de Evaluados por Estrato y Conectividad

- **Tipo de Gráfico:** Gráfico de Columnas Apiladas.
- **Pregunta:** ¿Cómo afecta el nivel socioeconómico la disponibilidad de internet?
- **Variables:** fami_estratovivienda, fami_tieneinternet, Total_Evaluados.
- **Procedimiento:** Agrupación volumétrica por estrato socioeconómico segmentada por tenencia de internet.
- **Evidencia:** Gráfico de columnas apiladas.
- **Hallazgo:** En los estratos 1 y 2, la proporción de estudiantes sin internet supera el 35%, contrastando con los estratos 3 en adelante donde supera el 70%.
- **Interpretación:** La brecha digital está directamente condicionada por la capacidad económica familiar.
- **Utilidad:** Ayuda a priorizar la asignación presupuestal de infraestructura tecnológica hacia los estratos 1 y 2.
- **Limitación:** No evalúa subsidios o planes móviles de corto alcance.

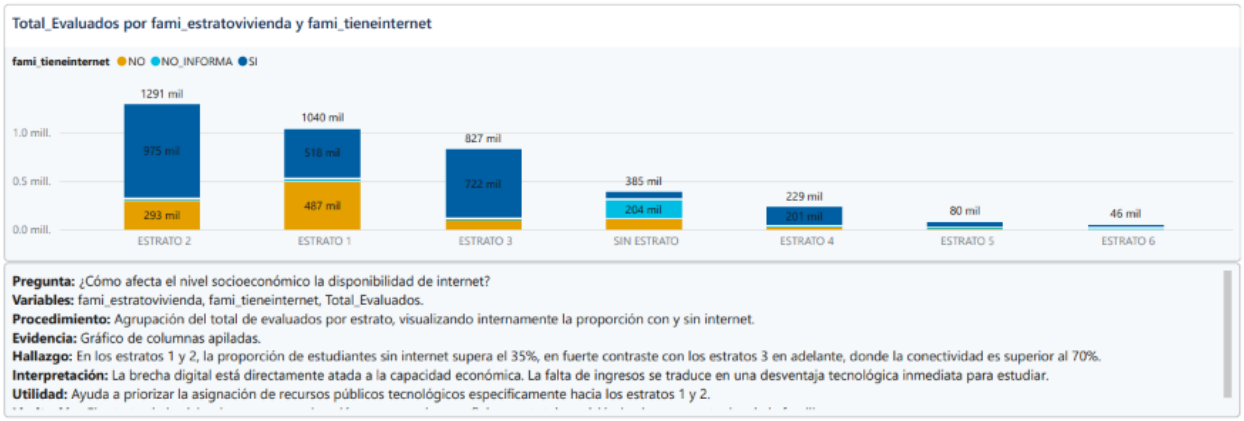
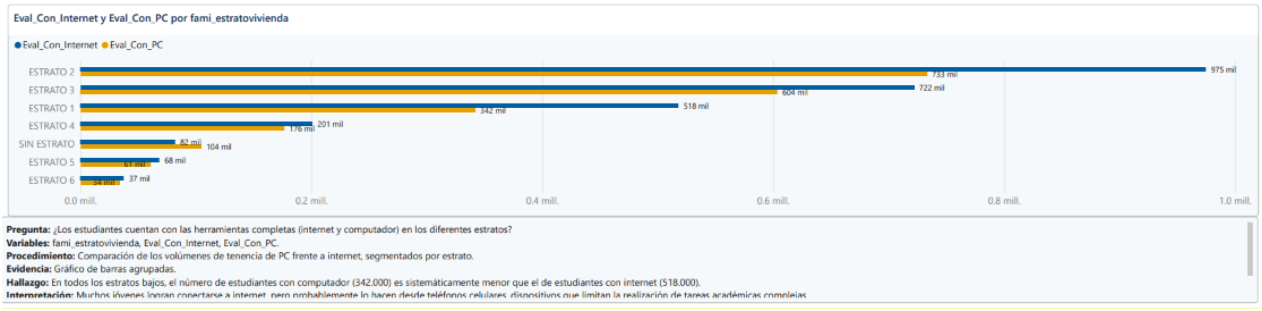


Gráfico 1.3: Comparativa de Acceso a Internet vs. Computador por Estrato

- **Tipo de Gráfico:** Gráfico de Barras Agrupadas.
- **Pregunta:** ¿Los estudiantes cuentan con las herramientas completas (internet y computador) en los diferentes estratos?
- **Variables:** fami_estratovivienda, Eval_Con_Internet, Eval_Con_PC.
- **Procedimiento:** Comparativa en paralelo de los volúmenes de tenencia de PC frente a internet por nivel de estrato.
- **Evidencia:** Gráfico de barras agrupadas horizontales.
- **Hallazgo:** En los estratos bajos, el número de estudiantes con computador (342,000) es menor que el de estudiantes con internet (518,000).
- **Interpretación:** Muchos jóvenes se conectan mediante teléfonos celulares, dispositivo poco óptimo para actividades académicas complejas.
- **Utilidad:** Redirige las estrategias públicas hacia la dotación directa de hardware y equipos de cómputo.
- **Limitación:** No distingue entre equipos de uso exclusivo del estudiante o compartidos con el núcleo familiar.



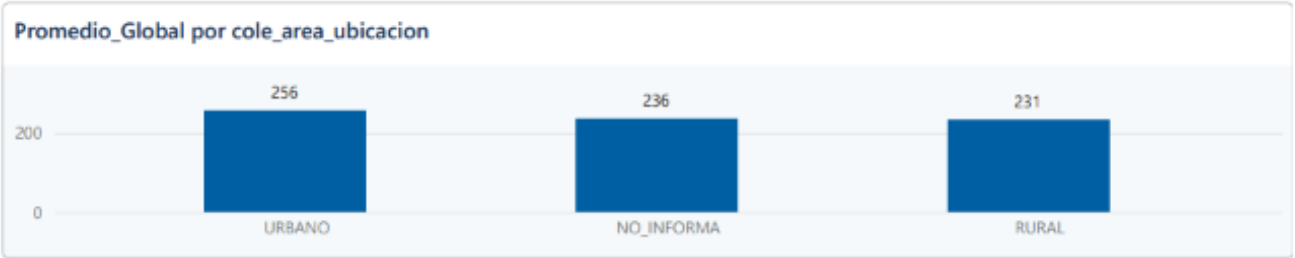
Tablero 2: Análisis Territorial y Geográfico

- **Enunciado General del Tablero:** Evaluación de las disparidades regionales, urbanas y rurales en el rendimiento académico y la infraestructura tecnológica en Santander y el país.



Gráfico 2.1: Promedio de Puntaje Global por Zona Geográfica

- **Tipo de Gráfico:** Gráfico de Columnas Agrupadas y Tarjetas de Resumen.
- **Pregunta:** ¿Existe una diferencia empírica en el desempeño global entre estudiantes de colegios urbanos y rurales?
- **Variables:** cole_area_ubicacion, Promedio_Global.
- **Procedimiento:** Cálculo de la media aritmética del puntaje global agrupado por la zona del establecimiento.
- **Evidencia:** Tarjetas de promedio y gráfico de columnas.
- **Hallazgo:** El promedio urbano se sitúa en 256 puntos frente a 231 puntos en la zona rural, evidenciando una brecha de 24 puntos.
- **Interpretación:** El entorno geográfico institucional condiciona severamente el desempeño base debido a diferencias de recursos.
- **Utilidad:** Justifica la creación de programas de refuerzo escolar y puntajes diferenciales rurales.
- **Limitación:** La clasificación binaria agrupa realidades internas muy heterogéneas.



Pregunta: ¿Existe una diferencia empírica en el desempeño global entre estudiantes de colegios urbanos y rurales?
Variables: cole_area_ubicacion, Promedio_Global.
Procedimiento: Cálculo y comparación de la media aritmética del puntaje global agrupado por la zona geográfica del colegio.
Evidencia: Tarjetas de promedio y gráfico de columnas agrupadas.
Hallazgo: El promedio en áreas urbanas es de 256 puntos, superando al promedio rural de 231 puntos, lo que marca una brecha directa de 24 puntos en contra del campo.
Interpretación: El entorno geográfico de la institución educativa condiciona fuertemente el desempeño base. Las escuelas rurales operan

Gráfico 2.2: Penetración de Conectividad por Zona Geográfica (100% Apilado)

- **Tipo de Gráfico:** Gráfico de Barras Apiladas al 100%.
- **Pregunta:** ¿Qué tan profunda es la desconexión tecnológica en el campo comparada con las ciudades?
- **Variables:** cole_area_ubicacion, fami_tieneinternet, Total_Evaluados.
- **Procedimiento:** Distribución porcentual relativa de la tenencia de internet dentro de cada zona geográfica.
- **Evidencia:** Gráfico de barras 100% apiladas.
- **Hallazgo:** En cabeceras urbanas el 36% reporta internet fijo, mientras que en la ruralidad la proporción favorable cae al 32%.
- **Interpretación:** La brecha digital presenta un componente territorial crítico que margina la conectividad rural.
- **Utilidad:** Permite a las secretarías focalizar la instalación de antenas satelitales institucionales.
- **Limitación:** Evalúa el hogar del estudiante y no la conectividad directa del aula de clases.

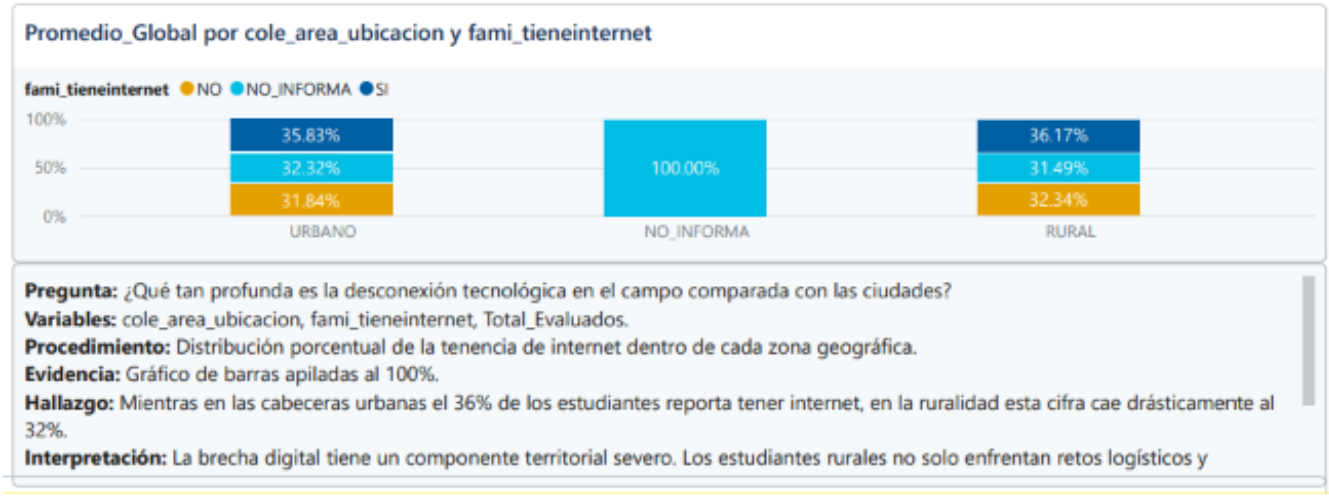
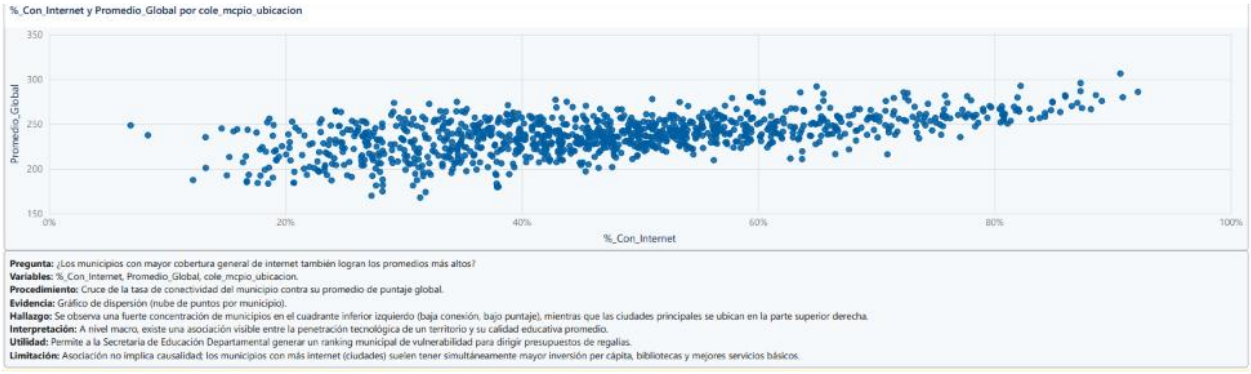


Gráfico 2.3: Relación entre Tasa de Conectividad Municipal y Promedio Global

- **Tipo de Gráfico:** Gráfico de Dispersión (Nube de Puntos).
- **Pregunta:** ¿Los municipios con mayor cobertura general de internet también logran los promedios más altos?
- **Variables:** %_Con_Internet, Promedio_Global, cole_mcpio_ubicacion.
- **Procedimiento:** Cruce bivariado entre la tasa de conectividad del municipio y su puntaje global medio.
- **Evidencia:** Gráfico de dispersión municipal.
- **Hallazgo:** Concentración de municipios en el cuadrante inferior izquierdo (baja conexión/bajo puntaje) frente a las ciudades principales en el superior derecho.
- **Interpretación:** Existe una correlación positiva macro entre la penetración tecnológica territorial y la calidad educativa.
- **Utilidad:** Generación de un ranking municipal de vulnerabilidad para asignación de recursos de regalías.
- **Limitación:** Correlación no implica causalidad directa debido a mayores inversiones per cápita urbanas.



Tablero 3: Comportamiento Temporal (Efecto Pandemia e Histórico)

- **Enunciado General del Tablero:** Seguimiento diacrónico del rendimiento académico y la evolución de la dotación tecnológica durante el periodo 2019–2023.

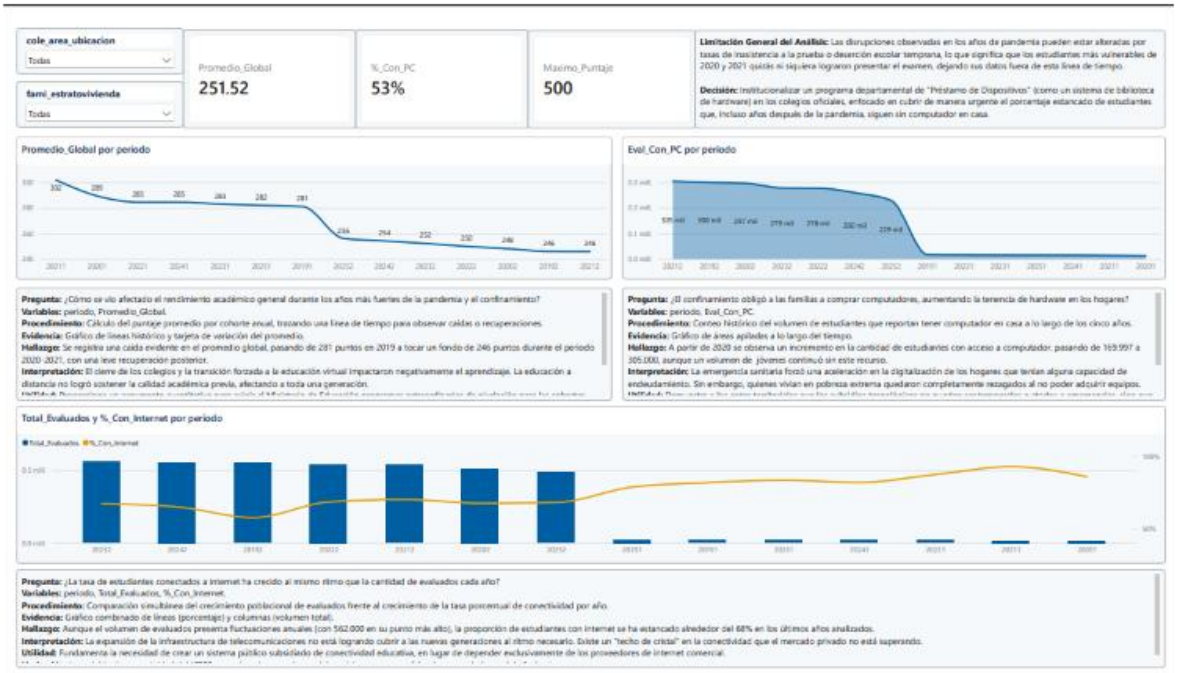


Gráfico 3.1: Evolución Histórica del Promedio Global por Periodo

- **Tipo de Gráfico:** Gráfico de Líneas de Tendencia.
- **Pregunta:** ¿Cómo se vio afectado el rendimiento académico general durante los años más fuertes de la pandemia?
- **Variables:** periodo, Promedio_Global.
- **Procedimiento:** Cálculo del puntaje promedio por cohorte semestral/anual en la línea de tiempo.
- **Evidencia:** Gráfico de líneas histórico.
- **Hallazgo:** Caída evidente del promedio global de 281 puntos en 2019 a un fondo de 246 puntos en 2020–2021.
- **Interpretación:** El cierre de colegios y la virtualidad forzada impactaron negativamente el aprendizaje generacional.
- **Utilidad:** Sustenta la creación de planes de choque pedagógicos de recuperación postpandemia.
- **Limitación:** Posible sesgo por deserción escolar temporal de estudiantes vulnerables que no presentaron la prueba en esos años.



Gráfico 3.2: Evolución Histórica de Tenencia de Computador en Hogares

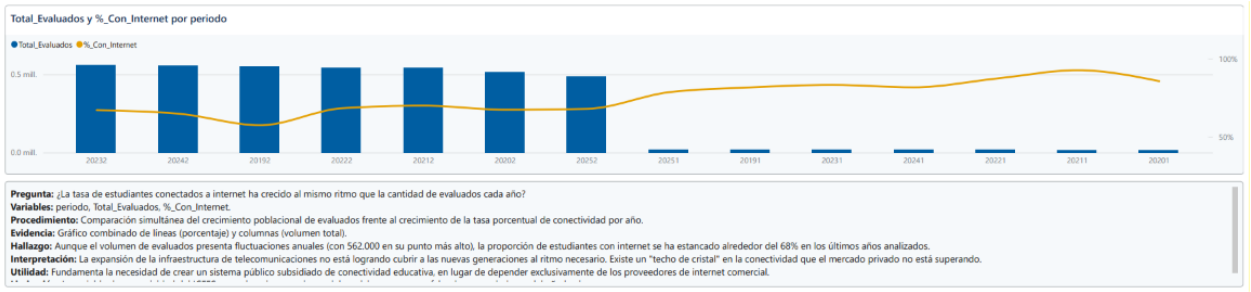
- **Tipo de Gráfico:** Gráfico de Áreas Apiladas.
- **Pregunta:** ¿El confinamiento obligó a las familias a comprar computadores, aumentando la tenencia de hardware?
- **Variables:** periodo, Eval_Con_PC.
- **Procedimiento:** Conteo histórico del volumen de estudiantes con computador en casa a lo largo de las cohortes.
- **Evidencia:** Gráfico de áreas en el tiempo.
- **Hallazgo:** Incremento del acceso a computador a partir de 2020, pasando de 169,997 a 305,000 evaluados con equipo.
- **Interpretación:** La emergencia sanitaria aceleró la digitalización en hogares con capacidad de endeudamiento.
- **Utilidad:** Muestra el esfuerzo económico extraordinario realizado por los hogares.
- **Limitación:** No especifica si los equipos eran nuevos o dispositivos compartidos.



Pregunta: ¿El confinamiento obligó a las familias a comprar computadores, aumentando la tenencia de hardware en los hogares?
Variables: periodo, Eval_Con_PC.
Procedimiento: Conteo histórico del volumen de estudiantes que reportan tener computador en casa a lo largo de los cinco años.
Evidencia: Gráfico de áreas apiladas a lo largo del tiempo.
Hallazgo: A partir de 2020 se observa un incremento en la cantidad de estudiantes con acceso a computador, pasando de 169.997 a 305.000, aunque un volumen de jóvenes continuó sin este recurso.
Interpretación: La emergencia sanitaria forzó una aceleración en la digitalización de los hogares que tenían alguna capacidad de endeudamiento. Sin embargo, quienes vivían en pobreza extrema quedaron completamente rezagados al no poder adquirir equipos.

Gráfico 3.3: Tasa de Conectividad vs. Volumen Total de Evaluados por Periodo

- **Tipo de Gráfico:** Gráfico Combinado (Líneas y Columnas).
- **Pregunta:** ¿La tasa de estudiantes conectados a internet ha crecido al mismo ritmo que la cantidad de evaluados?
- **Variables:** periodo, Total_Evaluados, %_Con_Internet.
- **Procedimiento:** Comparación simultánea del volumen de evaluados frente al porcentaje de conectividad anual.
- **Evidencia:** Gráfico combinado de barras y líneas de porcentaje.
- **Hallazgo:** Estancamiento de la proporción de conectividad alrededor del 68% en los últimos periodos analizados.
- **Interpretación:** Existe un "techo de cristal" en la conectividad que el mercado privado no logra superar en clases vulnerables.
- **Utilidad:** Fundamenta la necesidad de un sistema público subsidiado de conectividad educativa.
- **Limitación:** Variaciones metodológicas de captura en formularios del ICFES entre años.



Tablero 4: Análisis Multivariado

- **Enunciado General del Tablero:** Cruce conjunto de variables socioeconómicas, capital cultural familiar, infraestructura tecnológica y naturaleza jurídica de la institución.

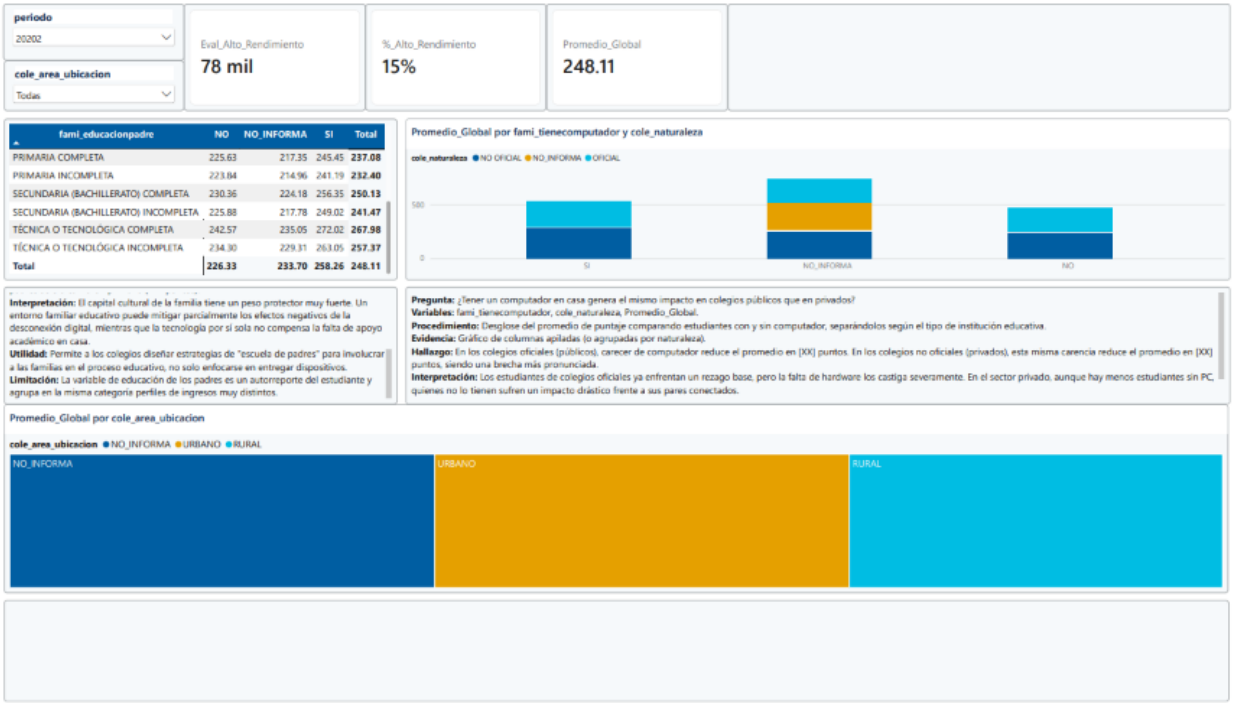
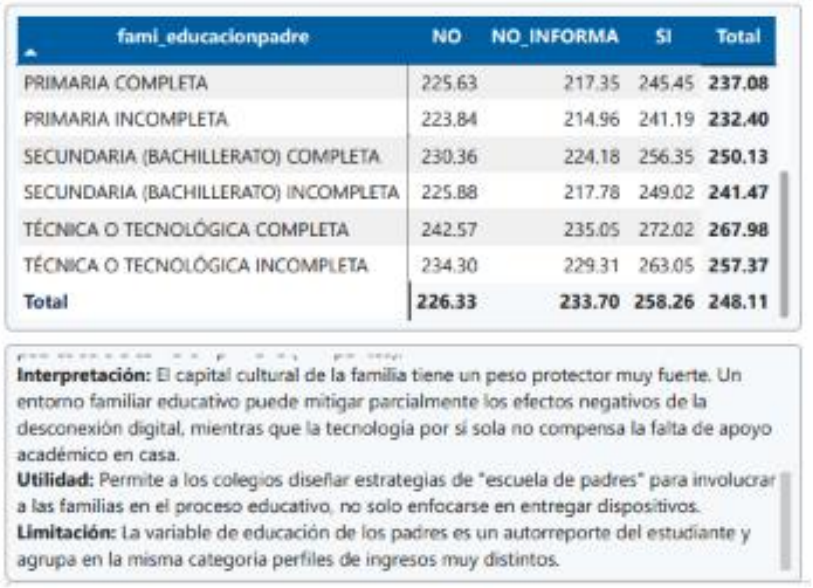


Gráfico 4.1: Matriz de Puntaje Global por Educación de Padres y Conectividad

- **Tipo de Gráfico:** Tabla Matriz con Formato Condicional.
- **Pregunta:** ¿De qué manera el nivel educativo de los padres modula el impacto de no tener internet en casa?
- **Variables:** fami_educacionpadre, fami_tieneinternet, Promedio_Global.
- **Procedimiento:** Tabla de contingencia cruzando nivel educativo del padre y tenencia de internet frente al puntaje medio.
- **Evidencia:** Matriz de datos tabulados.
- **Hallazgo:** Estudiantes sin internet cuyos padres poseen educación técnica completa alcanzan 242.57 puntos, superando a alumnos con internet cuyos padres solo tienen primaria (245.45 puntos).
- **Interpretación:** El capital cultural en el hogar ejerce un peso protector capaz de mitigar parcialmente la carencia tecnológica.
- **Utilidad:** Orienta el diseño de estrategias de "escuela de padres" en las instituciones educativas.
- **Limitación:** La educación de los padres es una variable de autorreporte estudiantil.

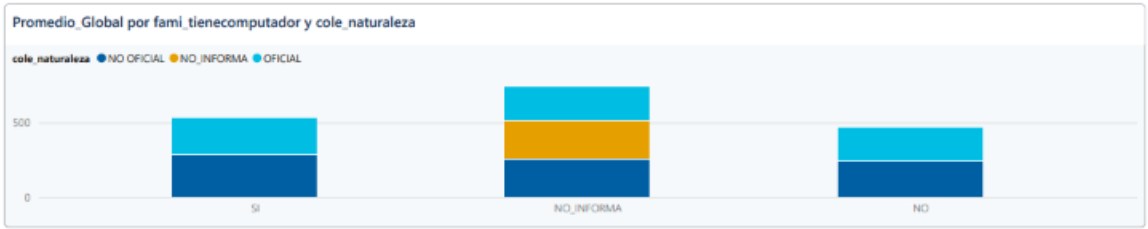


fami_educacionpadre	NO	NO_INFORMA	SI	Total
PRIMARIA COMPLETA	225.63	217.35	245.45	**237.08**
PRIMARIA INCOMPLETA	223.84	214.96	241.19	**232.40**
SECUNDARIA (BACHILLERATO) COMPLETA	230.36	224.18	256.35	**250.13**
SECUNDARIA (BACHILLERATO) INCOMPLETA	225.88	217.78	249.02	**241.47**
TÉCNICA O TECNOLÓGICA COMPLETA	242.57	235.05	272.02	**267.98**
TÉCNICA O TECNOLÓGICA INCOMPLETA	234.30	229.31	263.05	**257.37**
Total	**226.33**	**233.70**	**258.26**	**248.11**

Interpretación: El capital cultural de la familia tiene un peso protector muy fuerte. Un entorno familiar educativo puede mitigar parcialmente los efectos negativos de la desconexión digital, mientras que la tecnología por sí sola no compensa la falta de apoyo académico en casa.
Utilidad: Permite a los colegios diseñar estrategias de "escuela de padres" para involucrar a las familias en el proceso educativo, no solo enfocarse en entregar dispositivos.
Limitación: La variable de educación de los padres es un autorreporte del estudiante y agrupa en la misma categoría perfiles de ingresos muy distintos.

Gráfico 4.2: Promedio Global por Tenencia de Computador y Naturaleza del Colegio

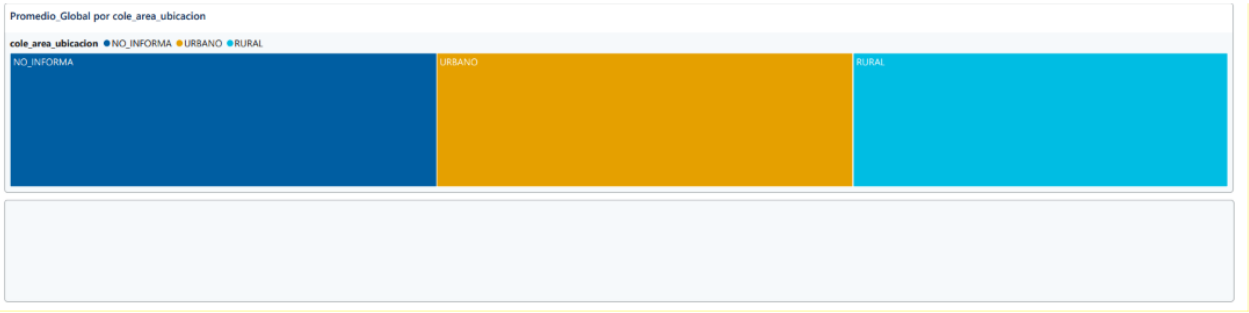
- **Tipo de Gráfico:** Gráfico de Columnas Apiladas.
- **Pregunta:** ¿Tener un computador en casa genera el mismo impacto en colegios públicos que en privados?
- **Variables:** fami_tienecomputador, cole_naturaleza, Promedio_Global.
- **Procedimiento:** Desglose del puntaje medio comparando tenencia de PC segmentado por naturaleza del colegio.
- **Evidencia:** Gráfico de columnas apiladas por naturaleza institucional.
- **Hallazgo:** En colegios oficiales la falta de PC reduce el promedio considerablemente, pero en privados la brecha de puntaje es aún más drástica.
- **Interpretación:** Los colegios privados exigen metodologías digitales avanzadas donde carecer de equipo aísla severamente al alumno.
- **Utilidad:** Alerta a instituciones privadas sobre la urgencia de esquemas de inclusión tecnológica para becarios.
- **Limitación:** La baja proporción de alumnos sin PC en colegios privados genera mayor volatilidad estadística.



Pregunta: ¿Tener un computador en casa genera el mismo impacto en colegios públicos que en privados?
Variables: fami_tienecomputador, cole_naturaleza, Promedio_Global.
Procedimiento: Desglose del promedio de puntaje comparando estudiantes con y sin computador, separándolos según el tipo de institución educativa.
Evidencia: Gráfico de columnas apiladas (o agrupadas por naturaleza).
Hallazgo: En los colegios oficiales (públicos), carecer de computador reduce el promedio en [XX] puntos. En los colegios no oficiales (privados), esta misma carencia reduce el promedio en [XX] puntos, siendo una brecha más pronunciada.
Interpretación: Los estudiantes de colegios oficiales ya enfrentan un rezago base, pero la falta de hardware los castiga severamente. En el sector privado, aunque hay menos estudiantes sin PC, quienes no lo tienen sufren un impacto drástico frente a sus pares conectados.

Gráfico 4.3: Perfilamiento de Alto Rendimiento por Ubicación y Estrato

- **Tipo de Gráfico:** Mapa de Árbol (Treemap).
- **Pregunta:** ¿El cruce de zona geográfica, estrato y conectividad genera perfiles de alto rendimiento extremo?
- **Variables:** cole_area_ubicacion, fami_estratovivienda, fami_tieneinternet, Eval_Alto_Rendimiento.
- **Procedimiento:** Segmentación cruzada simultánea para aislar la proporción de puntajes superiores a 350 puntos.
- **Evidencia:** Gráfico de mapa de árbol interactivo.
- **Hallazgo:** El 85% de los estudiantes catalogados en "Alto Rendimiento" se concentra estrictamente en zonas urbanas, estrato 3 en adelante, con PC e internet fijo.
- **Interpretación:** El éxito académico de alto nivel sigue condicionado por la acumulación previa de ventajas socioeconómicas.
- **Utilidad:** Demuestra que las becas de excelencia deben complementarse con apoyos tempranos de conectividad.
- **Limitación:** No evalúa horas extracurriculares de estudio autónomo ni preicfes externos.



10. Limitaciones Generales y Decisiones Sustentadas

- **Limitación General:** El uso de microdatos censales de pruebas estandarizadas limita la medición de factores psicológicos o dinámicas intrapersonales del aula; asimismo, los registros "NO INFORMA" generan puntos ciegos.
- **Decisión Sustentada:** Diseñar un programa departamental de dotación tecnológica prioritaria en estratos 1 y 2, combinando "Préstamo de Dispositivos" y Aulas Digitales Offline en zonas rurales.

11. Conclusiones del Proyecto

El análisis exploratorio de la Etapa 4 demostró empíricamente que la brecha digital multiplica la desigualdad educativa en Colombia. Los tableros en Power BI consolidan una herramienta robusta de Business Intelligence integrada con Flask para la toma de decisiones informadas.

12. Enlaces del Proyecto

- URL del repositorio público en GitHub:
  https://github.com/Rockbayo/MD_Proyecto_Educacion.git

- URL de la rama de desarrollo:
  https://github.com/Rockbayo/MD_Proyecto_Educacion/tree/feature/etapa-4

- URL del Pull Request:
  https://github.com/Rockbayo/MD_Proyecto_Educacion/pull/20

- URL de la aplicación Flask publicada:
  https://md-proyecto-educacion.onrender.com/

- Power BI:
  https://app.powerbi.com/groups/me/reports/e88e30a1-d605-413f-a622-3c66297fa2f8?pbi_source=desktop

15. Referencias Bibliográficas

Batini, C., & Scannapieco, M. (2016). *Data and information quality: Dimensions, principles and techniques*. Springer.

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). John Wiley & Sons.

Microsoft. (2024). *Integration Services (SSIS) concepts and architecture*. Microsoft Learn. Recuperado de https://learn.microsoft.com/sql/integration-services/

Instituto Colombiano para la Evaluación de la Educación [ICFES]. (2023). *Bases de datos abiertas de las pruebas Saber 11 (2019–2023)*. Ministerio de Educación Nacional.

s