Proyecto

Educación, acceso y desempeño académico

Semana 13

Etapa 5

Análisis Multidimensional

Oscar Giovanni Robayo

Oscar Felipe Delgado

Facultad de Ingeniería

Programa de Ingeniería de Sistemas y Computación

Universidad de Cundinamarca, Extensión Chía

Minería De Datos

Chía, Cundinamarca

Noviembre 2026

Enlaces del Proyecto

- URL del repositorio público en GitHub:
  https://github.com/Rockbayo/MD_Proyecto_Educacion.git

- URL de la rama de desarrollo:
  https://github.com/Rockbayo/MD_Proyecto_Educacion/tree/feature/etapa-5

- URL del Pull Request:
  https://github.com/Rockbayo/MD_Proyecto_Educacion/pull/29

- URL de la aplicación Flask publicada:
  https://md-proyecto-educacion.onrender.com/

2. Tema, propósito y población estudiada

2.1. Tema y propósito

El proyecto “Educación, acceso y desempeño académico” (EduMetricsCO) es un proyecto de minería de datos que estudia la relación entre la brecha digital (conectividad a internet y tenencia de computador en el hogar) y el desempeño académico de los estudiantes de grado 11 en las pruebas Saber 11 del ICFES, entre 2019-1 y 2025-2. Las etapas previas formularon los requerimientos (Etapa 1), diagnosticaron y depuraron la calidad del dato (Etapa 2), construyeron el repositorio relacional (Etapa 3) y documentaron doce conocimientos evidentes en Power BI (Etapa 4).

El propósito de la Etapa 5 es profundizar esos hallazgos mediante un **análisis multidimensional**: se construye un modelo estrella sobre una base SQLite, se consultan las medidas desde distintas dimensiones y niveles de detalle (drill-down, roll-up, slice, dice y pivot) y se presentan los resultados de forma interactiva en la sección “Análisis multidimensional” de la aplicación Flask.

2.2. Población y fuente de los datos

Población	Estudiantes de grado 11 que presentaron Saber 11 entre 2019-1 y 2025-2 (14 periodos semestrales). Se conserva la misma población y el mismo conjunto de datos de las etapas anteriores.
Fuente	Instituto Colombiano para la Evaluación de la Educación (ICFES), microdatos abiertos de Saber 11.
URL original	https://www.icfes.gov.co/data-icfes
Fuentes complementarias	Directorio Único de Establecimientos Educativos (DUE) del MEN y codificación territorial DIVIPOLA del DANE.
Cobertura analizada	2019-1 a 2025-2 · 4.541.655 registros tratados

2.3. Unidad de análisis, registros y granularidad

La **unidad de análisis** del proyecto es la presentación del examen Saber 11 de un estudiante (identificada en origen por `estu_consecutivo`). La **granularidad del modelo multidimensional** es distinta: cada registro de la tabla de hechos `fact_resultados_saber11` representa una celda agregada, definida por la combinación única de cuatro claves: periodo (`id_tiempo`), ubicación y tipo de colegio (`id_geografia`), perfil de acceso digital (`id_digital`) y perfil socioeconómico (`id_socioeconomico`). Cada fila resume a todos los estudiantes que comparten esa combinación y almacena su conteo (`num_evaluados`) y las sumas de sus puntajes. Así, 4.541.655 estudiantes quedan resumidos en 717.225 filas de hechos, sin pérdida de información poblacional.

2.4. Resumen del tratamiento previo y limitaciones de calidad

- **Volumen:** de 4.582.310 filas brutas de las 14 bases maestras del ICFES se consolidaron 4.541.655 registros válidos (40.655 registros descartados, 0,89 %).

- **Normalización textual y territorial:** las cadenas se estandarizaron a mayúsculas sin caracteres especiales, y la rotulación de departamentos y municipios se alineó con la codificación DIVIPOLA del DANE.
- **Calendarios A y B:** el calendario A (semestre 2, cerca del 90 % del volumen) y el calendario B (semestre 1, cerca del 10 %, principalmente colegios privados) se trataron de forma homogénea. Por esta razón la composición de los semestres no es equivalente y las comparaciones temporales se hacen por etapa o por año.
- **Esquemas ICFES:** se unificaron las taxonomías históricas de códigos de asignaturas y de escalas de desempeño en inglés.

Limitaciones de calidad que pueden afectar los resultados:

- Variables como estrato, escolaridad de los padres y horas de internet son autorreportadas por el estudiante.
- La escolaridad del padre tiene 907.694 registros (19,99 %) en "No sabe / no informa" (ver sección 7.3).
- La conectividad se registra como SI/NO: no hay datos de ancho de banda (Mbps), latencia, costo ni estabilidad eléctrica.
- Los datos permiten observar asociaciones, no causalidad.

3. Relación con los conocimientos evidentes de la Etapa 4

La Etapa 4 identificó doce conocimientos evidentes (CE) con medidas bivariadas o panorámicas. La tabla los resume e indica cuáles requieren más profundidad y en qué vista de la Etapa 5 se retoman.

CE	Conocimiento evidente (Etapa 4)	Qué falta profundizar	Se retoma en
1.1	67,2 % de los estudiantes tiene internet en el hogar; 1,49 millones están desconectados.	Cómo se distribuye la desconexión por territorio y perfil.	Vista 1 (CM 1.1)
1.2	Acceso a internet: 42,1 % en estrato 1 frente a 96,8 % en estrato 6 (54,7 p. p.).	Efecto del estrato al cruzarlo con hardware y escolaridad.	Vista 3 (CM 3.2)
1.3	Brecha de 14,2 p. p. entre internet y computador; 645.000 estudiantes con internet pero sin computador.	Diferenciar "solo móvil" de "acceso pleno".	Vistas 1 y 3 (perfil TIC)
2.1	Puntaje urbano 256,4 frente a rural 232,1 (brecha de 24,3 pts).	Variación entre regiones y departamentos, y combinación con acceso digital.	Vista 1 (CM 1.1, 1.2)
2.2	En sedes rurales solo el 32,4 % tiene internet y el 21,1 % computador.	Rendimiento rural según perfil de acceso por departamento.	Vista 1 (CM 1.2)
2.3	Municipios con internet inferior al 30 % no superan 228 pts de promedio.	Nivel de detalle intermedio (región → departamento).	Vista 1 (drill-down)
3.1	Caída a 246,3 pts en 2020-2021 (−6,7 pts frente a 253,0 en 2019).	Si la caída fue distinta por sector del colegio.	Vista 2 (CM 2.1)
3.2	La tenencia de computador aumentó 8,3 % entre 2020 y 2022.	Relación entre hardware y puntaje por etapa.	Vista 2 (CM 2.2)

CE	Conocimiento evidente (Etapa 4)	Qué falta profundizar	Se retoma en
3.3	La cobertura de internet se estancó en 70–71 % tras la reapertura.	Comparar etapas por sector y hardware.	Vista 2
4.1	Sin internet, hijos de padres con posgrado puntúan 38 pts más que hijos de padres sin primaria completa.	Si el computador modifica esa diferencia.	Vista 3 (CM 3.1)
4.2	Sin computador: −28,4 pts en colegios oficiales y −14,1 pts en privados.	Comportamiento por etapa de la pandemia.	Vista 2 (CM 2.2)
4.3	Perfil más vulnerable 211,8 pts frente a 318,4 del más favorecido (106,6 pts).	Intensidad de uso de internet y riesgo académico.	Vista 4 (CM 4.1, 4.2)

Nota sobre la base de la Etapa 4. El informe de la Etapa 4 trabajó con una muestra de 761.173 registros (colegios regulares de grado 11, calendario A, 2019–2023), depurada con SSIS para que el tablero de Power BI funcionara con fluidez. Esta etapa usa el censo completo de la misma fuente del ICFES: 4.541.655 registros de 14 semestres (2019-1 a 2025-2), sin muestreo. Por eso las cifras de los conocimientos evidentes (por ejemplo, 67,2 % con internet) pueden diferir de las del modelo completo; la relación entre etapas es cualitativa: los patrones de la Etapa 4 se contrastan y profundizan con la población completa.

La Etapa 5 no repite esas preguntas: cada vista cruza al menos dos dimensiones y permite cambiar el nivel de detalle, de modo que cada medida se recalcula al desagregar o agrupar.

4. Preguntas de análisis y justificación

Se formularon cuatro preguntas, una por vista. Entre las cuatro se usan las cuatro dimensiones del modelo y los cinco tipos de operación.

Pregunta 1 · Vista 1 · Territorial

Pregunta	¿Cómo varía la penalización por exclusión digital sobre el puntaje global y de matemáticas al desagregar desde las regiones hacia los departamentos y las zonas urbano-rurales?
Dimensiones y medidas	`dim_geografia` (región → departamento → zona) y `dim_acceso_digital` (perfil TIC). Medidas: puntaje global y de matemáticas, brecha neta, pérdida relativa y número de evaluados.
Aporte frente a la Etapa 4	La Etapa 4 comparó solo urbano frente a rural. Aquí se mide la diferencia por perfil de acceso dentro de cada territorio, lo que separa el efecto del territorio del acceso digital.

Pregunta 2 · Vista 2 · Temporal

Pregunta	¿Cómo evolucionó la brecha de rendimiento entre colegios públicos y privados a través de las etapas pre (2019), durante (2020-2021) y post-pandemia (2022-2025), y qué papel jugó la disponibilidad de hardware?
Dimensiones y medidas	`dim_tiempo` (etapa → año → periodo), `dim_geografia` (naturaleza del colegio) y `dim_acceso_digital` (computador). Medidas: puntaje global, brecha oficial–no oficial y diferencial de hardware.
Aporte frente a la Etapa 4	La Etapa 4 mostró la caída global. Aquí se descompone por sector y por hardware para ver quién concentra el cambio.

Pregunta 3 · Vista 3 · Capital cultural

Pregunta	¿En qué medida la disponibilidad de computador compensa o amplifica las desventajas de origen asociadas a la baja escolaridad parental?
Dimensiones y medidas	`dim_socioeconomica` (estrato, escolaridad, género) y `dim_acceso_digital` (computador). Medidas: puntajes por competencia y diferencial de hardware.
Aporte frente a la Etapa 4	Rota los ejes (pivot) y compara competencias: la Etapa 4 solo comparaba el puntaje global.

Pregunta 4 · Vista 4 · Hábitos TIC

Pregunta	¿Cuál es el umbral de dedicación diaria a internet a partir del cual el uso de la red deja de favorecer el dominio del inglés y comienza a incrementar el riesgo de bajo rendimiento global?
Dimensiones y medidas	`dim_acceso_digital` (horas de dedicación) y `dim_geografia` (área y sector). Medidas: puntaje de inglés, tasa de bilingüismo, tasa de riesgo crítico y tasa de alto rendimiento.
Aporte frente a la Etapa 4	Sustituye la variable binaria de internet por una medida de intensidad y examina los extremos de la distribución.

5. Diseño del modelo estrella

El modelo sigue el enfoque dimensional de Kimball: una tabla de hechos y cuatro dimensiones con perspectivas reales del problema (cuándo, dónde, con qué acceso digital y en qué contexto socioeconómico). Se implementó en SQLite (`edumetrics_olap.db`, 72,33 MB).

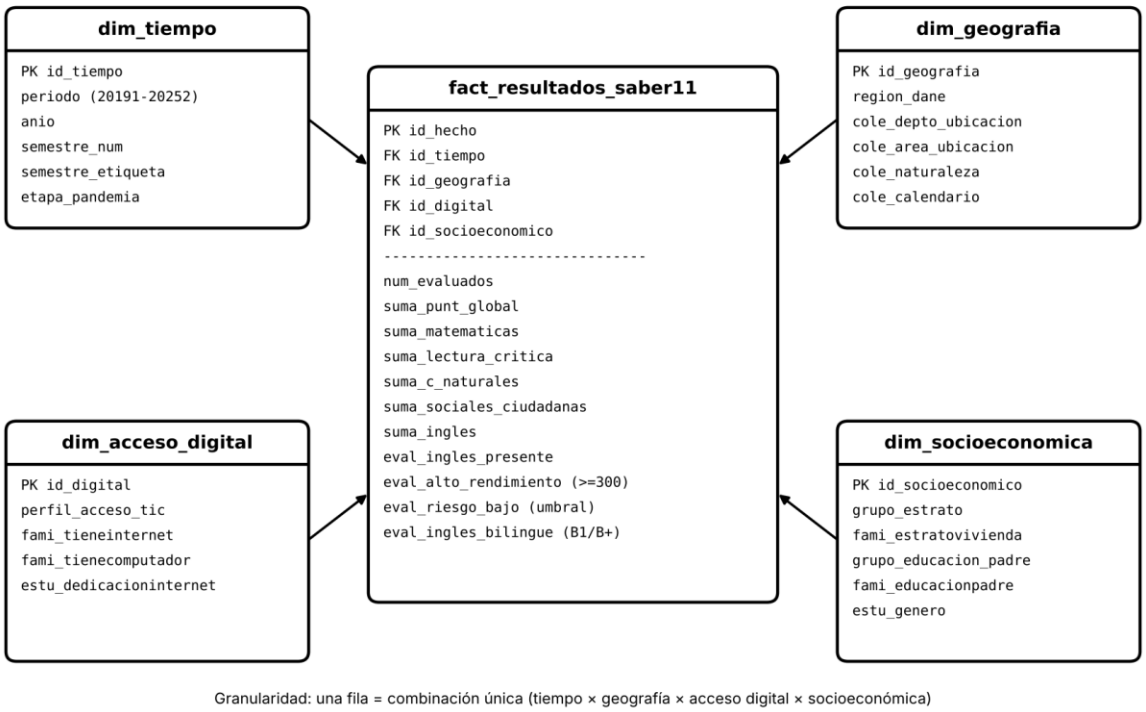


Figura 1. *Diagrama del modelo estrella: tabla de hechos y cuatro dimensiones.*

5.1. Tabla de hechos y granularidad

La tabla `fact_resultados_saber11` concentra las medidas de desempeño para analizar el rendimiento en Saber 11 desde las cuatro perspectivas. **Granularidad:** una fila por cada combinación única de `id_tiempo`, `id_geografia`, `id_digital` e `id_socioeconomico`; cada fila agrupa a los estudiantes que comparten esa combinación. Se mantiene una sola granularidad en toda la tabla, por lo que ninguna relación multiplica los valores.

5.2. Dimensiones y atributos

Dimensión	Filas	Atributos
`dim_tiempo`	14	periodo (20191–20252), anio, semestre_num, semestre_etiqueta, etapa_pandemia (Pre-pandemia, Pandemia, Post-pandemia)
`dim_geografia`	198	region_dane (8 regiones), cole_depto_ubicacion (33 departamentos), cole_area_ubicacion (urbano/rural), cole_naturaleza (oficial/no oficial), cole_calendario (A/B)
`dim_acceso_digital`	54	perfil_acceso_tic (Pleno, Solo móvil, Offline, Exclusión absoluta), fami_tieneinternet, fami_tienecomputador, estu_dedicacioninternet
`dim_socioeconomica`	220	grupo_estrato, fami_estratovivienda, grupo_educacion_padre, fami_educacionpadre, estu_genero

5.3. Claves primarias y foráneas

Tabla	Tipo	Clave y relación
`fact_resultados_saber11`	PK	`id_hecho` (INTEGER, autoincremental)
`fact_resultados_saber11`	FK	`id_tiempo` → `dim_tiempo(id_tiempo)` (muchos a uno)
`fact_resultados_saber11`	FK	`id_geografia` → `dim_geografia(id_geografia)` (muchos a uno)
`fact_resultados_saber11`	FK	`id_digital` → `dim_acceso_digital(id_digital)` (muchos a uno)
`fact_resultados_saber11`	FK	`id_socioeconomico` → `dim_socioeconomica(id_socioeconomico)` (muchos a uno)
`dim_tiempo`, `dim_geografia`, `dim_acceso_digital`, `dim_socioeconomica`	PK	`id_tiempo`, `id_geografia`, `id_digital`, `id_socioeconomico` (INTEGER)

5.4. Medidas

Las medidas almacenadas en la tabla de hechos son aditivas (conteos y sumas). Los promedios y las tasas no se almacenan: se calculan en cada consulta como razón de sumas, de modo que se recalculan correctamente en cualquier nivel de agrupación. Nunca se promedian promedios ni se suman porcentajes.

Medida	Unidad	Fórmula	Agregación y uso
Evaluados	estudiantes	`SUM(num_evaluados)`	Aditiva en todas las dimensiones. Conteo de estudiantes (no de filas de hechos).
Puntaje global promedio	puntos (0–500)	`SUM(suma_punt_global) / SUM(num_evaluados)`	Promedio ponderado. No admite suma ni promedio simple de promedios.

Medida	Unidad	Fórmula	Agregación y uso
Puntaje por competencia (matemáticas, lectura, ciencias)	puntos (0–100)	`SUM(suma_x) / SUM(num_evaluados)`	Promedio ponderado por evaluados.
Puntaje de inglés	puntos (0–100)	`SUM(suma_ingles) / SUM(eval_ingles_presente)`	Denominador: quienes presentaron inglés.
Tasa de bilingüismo	%	`SUM(eval_ingles_bilingue) / SUM(eval_ingles_presente) × 100`	Proporción (B1/B+). Se recalcula en cada nivel.
Tasa de riesgo crítico	%	`SUM(eval_riesgo_bajo) / SUM(num_evaluados) × 100` (umbral < 220 pts)	Proporción sobre el total de evaluados del grupo.
Tasa de alto rendimiento	%	`SUM(eval_alto_rendimiento) / SUM(num_evaluados) × 100` (≥ 300 pts)	Proporción sobre el total de evaluados del grupo.
Brecha digital	puntos	Puntaje(Pleno) − Puntaje(Exclusión absoluta)	Diferencia de dos promedios del mismo territorio.
Pérdida relativa	%	(Pleno − Exclusión) / Pleno × 100	Denominador: promedio del grupo Pleno del mismo territorio.

5.5. Jerarquías

Jerarquía	Niveles (de general a detalle)	Dimensión / vista
Territorial	Región DANE (8) → Departamento (33) → Zona (urbano/rural)	`dim_geografia` · Vista 1
Temporal	Etapa de pandemia (3) → Año (2019–2025) → Periodo semestral (14)	`dim_tiempo` · Vista 2
Estratificación	Grupo de estrato (bajo 1–2, medio 3–4, alto 5–6) → Estrato de vivienda	`dim_socioeconomica` · Vistas 2 y 3
Capital cultural	Grupo de nivel educativo (primaria/ninguno, secundaria, técnica, superior/posgrado, no sabe) → Nivel específico	`dim_socioeconomica` · Vista 3
Acceso digital	Perfil TIC (Pleno, Solo móvil, Offline, Exclusión) → Internet / computador → Horas de dedicación	`dim_acceso_digital` · Vistas 1, 2 y 4

Cada nivel agrupa válidamente al siguiente (cada departamento pertenece a una sola región; cada periodo a un solo año y etapa).

6. Herramientas seleccionadas

Herramienta	Justificación
SQLite	Base relacional en un único archivo (72,33 MB), portable en Git y sin servidor. Con índices B-Tree sobre las claves foráneas resuelve agregaciones sobre 4,54 millones de registros en menos de 30 ms.
Python (pandas / scripts)	Transformación y carga reproducibles: `scripts/07_modelo_estrella_olap.py` procesa el archivo tratado por bloques de memoria controlada.
Flask	Backend ligero que expone la API analítica (`/api/v1/olap/...`) con SQL parametrizado, sin ORM, para controlar exactamente las agregaciones.
Chart.js	Visualizaciones interactivas en el navegador (barras, líneas, dona) que se redibujan al cambiar filtros.

Herramienta	Justificación
ReportLab y python-docx	Generación programática de los informes técnicos.
Power BI (Etapa 4)	Exploración previa y formulación de los conocimientos evidentes.

7. Procedimiento de transformación y carga

7.1. Pasos del proceso

1. **Lectura:** el script lee el archivo tratado de la Etapa 2 por bloques, sin cargarlo completo en memoria.
2. **Normalización:** cadenas a mayúsculas ASCII y códigos DIVIPOLA homologados.
3. **Derivación de atributos:** `etapa_pandemia` a partir del periodo; `region_dane` a partir del departamento; `perfil_acceso_tic` a partir de internet × computador; agrupaciones de estrato y escolaridad.
4. **Carga de dimensiones:** se generan los valores distintos de cada dimensión y se les asigna una clave sustituta.
5. **Carga de hechos:** se agrupa por las cuatro claves, se suman los puntajes y se cuentan evaluados e indicadores (`eval_*`).
6. **Validación:** el script genera `data/reports/validacion_modelo_estrella.json` con las comprobaciones de la sección 8.

7.2. Valores faltantes y categorías desconocidas

Se distinguieron tres situaciones: el **valor faltante** (sin respuesta), la **categoría desconocida** (el estudiante respondió “no sabe”) y la **respuesta negativa** (por ejemplo, internet = NO, que es un dato válido y no una omisión).

- **Escolaridad del padre:** 907.694 registros (19,99 %) eran omisión o “No sabe”. No se descartaron porque eliminarlos quitaría casi un millón de estudiantes y sesgaría la muestra hacia hogares de estratos medios y altos; tampoco se imputaron, para no falsear la relación entre escolaridad y puntaje. Se conservan como la categoría explícita **No sabe / No informa**, cuyo promedio es 238,1 pts.
- **Estrato:** los registros nulos o de zonas rurales sin estratificación se mapearon a **Sin estratificación / Rural disperso**.
- **Inglés:** las tasas de bilingüismo usan como denominador solo a quienes presentaron la prueba (`eval_ingles_presente`).

8. Validaciones del modelo y comparación con los datos de origen

8.1. Verificaciones de calidad

Se comprobó la unicidad de las claves de las cuatro dimensiones (14, 198, 54 y 220 claves distintas, iguales al número de filas), que no existen claves foráneas huérfanas en la tabla de hechos y que no hay combinaciones de claves duplicadas en las 717.225 filas. La coherencia de conteos y agregaciones se comprueba en 8.2.

Consultas de verificación:

```
-- Unicidad de la clave en una dimensión (repetir por dimensión)
SELECT COUNT(*) AS filas, COUNT(DISTINCT id_geografia) AS claves FROM dim_geografia;

-- Claves foráneas huérfanas (repetir por dimensión)
SELECT COUNT(*) FROM fact_resultados_saber11 f
LEFT JOIN dim_tiempo t ON f.id_tiempo = t.id_tiempo WHERE t.id_tiempo IS NULL;

-- Duplicados en la tabla de hechos
SELECT id_tiempo, id_geografia, id_digital, id_socioeconomico, COUNT(*) AS c
FROM fact_resultados_saber11 GROUP BY 1,2,3,4 HAVING c > 1;
```

8.2. Tres comprobaciones contra los datos tratados

Comprobación	Datos tratados (CSV)	Modelo estrella	Diferencia	Resultado
1. Cuadratura de población (evaluados)	4.541.655	4.541.655	0	Exitosa
2. Puntaje global promedio	252,4228	252,4228	0,0000	Exitosa
2. Matemáticas / lectura / inglés (promedios)	51,2312 / 53,0841 / 50,2534	51,2312 / 53,0841 / 50,2534	0,0000	Exitosa
3. Suma por tramo de dedicación a internet (evaluados)	4.541.655	4.541.655 (179.292 + 523.885 + 874.423 + 933.672 + 1.162.331 + 868.052)	0	Exitosa
3. Suma por tramo de casos con riesgo (< 220 pts)	1.368.358 (30,13 %)	1.368.358 (96.518 + 228.631 + 288.993 + 305.914 + 264.567 + 183.735)	0	Exitosa

Los seis tramos de dedicación a internet suman exactamente el total de evaluados (comprobación 1) y los casos de riesgo por tramo suman 1.368.358, es decir, una tasa nacional de 30,13 %. No hay diferencias que explicar: el modelo reproduce los conteos y promedios del archivo de origen. La reducción de 4.582.310 a 4.541.655 registros ocurre antes del modelo (depuración de la Etapa 2) y no en la carga.

9. Operaciones multidimensionales: consultas y evidencias

Las cinco operaciones se ejecutan desde la aplicación mediante consultas SQL parametrizadas al modelo estrella (rutas `/api/v1/olap/...` de `app.py`). Las capturas de cada operación se presentan en la sección 10, junto a la vista donde se ejecuta. En drill-down y roll-up las medidas se **recalculan** como razón de sumas en el nuevo nivel: el promedio regional no es el promedio de los promedios departamentales. Cambiar solo el tipo de gráfica no se considera operación multidimensional.

9.1. Drill-down (Vista 1)

Dimensiones y medidas: `dim_geografia` (región → departamento → zona) × `dim_tiempo`; puntaje global, puntaje de matemáticas y evaluados. **Nivel y filtros:** De la región DANE al departamento: nivel "Departamentos", región = Caribe, periodo consolidado, sector "Todos". **Procedimiento:** El botón "Departamentos" desciende un nivel; la consulta agrupa por departamento dentro de la región seleccionada y recalcula los promedios.

```
SELECT g.cole_depto_ubicacion AS territorio,
       SUM(f.num_evaluados) AS n,
       ROUND(CAST(SUM(f.suma_punt_global) AS REAL) / SUM(f.num_evaluados), 2) AS prom_global,
       ROUND(CAST(SUM(f.suma_matematicas) AS REAL) / SUM(f.num_evaluados), 2) AS prom_mat
FROM fact_resultados_saber11 f
JOIN dim_geografia g ON f.id_geografia = g.id_geografia
JOIN dim_tiempo t ON f.id_tiempo = t.id_tiempo
WHERE g.region_dane = 'Región Caribe'
GROUP BY g.cole_depto_ubicacion
ORDER BY prom_global DESC;
```

Interpretación: dentro de la región Caribe los promedios varían entre departamentos: Atlántico 247,16 pts (247.381 evaluados), Bolívar 238,24 pts (188.419) y La Guajira 221,05 pts (78.924). La región oculta diferencias de más de 26 pts entre sus departamentos.

9.2. Roll-up (Vista 1)

Dimensiones y medidas: `dim_geografia` (departamento → región DANE); puntaje global, puntaje de matemáticas y evaluados. **Nivel y filtros:** De 33 departamentos a 8 regiones: nivel "Regiones", periodo consolidado, sector "Todos". Solo se muestran regiones con más de 50 evaluados. **Procedimiento:** El botón "Regiones" agrupa por `region_dane` y los promedios se recalculan con la razón ponderada.

```
SELECT g.region_dane AS territorio,
       SUM(f.num_evaluados) AS n,
       ROUND(CAST(SUM(f.suma_punt_global) AS REAL) / SUM(f.num_evaluados), 2) AS prom_global,
       ROUND(CAST(SUM(f.suma_matematicas) AS REAL) / SUM(f.num_evaluados), 2) AS prom_mat
FROM fact_resultados_saber11 f
JOIN dim_geografia g ON f.id_geografia = g.id_geografia
JOIN dim_tiempo t ON f.id_tiempo = t.id_tiempo
GROUP BY g.region_dane
HAVING SUM(f.num_evaluados) > 50
ORDER BY prom_global DESC;
```

Interpretación: Bogotá registra el promedio más alto (277,58 pts; 698.905 evaluados), seguida de Centro Oriente (259,45 pts; 694.763) y de la región Caribe (236,42 pts; 1.029.910): 41,16 pts entre Bogotá y el Caribe. Se usa en el CM 1.1.

9.3. Slice (Vista 2)

Dimensiones y medidas: `dim_tiempo` (etapa de pandemia) × `dim_geografia` (naturaleza del colegio); puntaje global y evaluados. **Nivel y filtros:** Se fija un valor de una dimensión: etapa = Confinamiento y pandemia (2020-2021). **Procedimiento:** El filtro de etapa selecciona el subconjunto y el puntaje se calcula por sector.

```
SELECT t.etapa_pandemia, g.cole_naturaleza,
       SUM(f.num_evaluados) AS n,
       ROUND(CAST(SUM(f.suma_punt_global) AS REAL) / SUM(f.num_evaluados), 2) AS prom_global
FROM fact_resultados_saber11 f
JOIN dim_geografia g ON f.id_geografia = g.id_geografia
JOIN dim_tiempo t ON f.id_tiempo = t.id_tiempo
WHERE t.etapa_pandemia = '2. Confinamiento y Pandemia (2020-2021)'
  AND g.cole_naturaleza IN ('OFICIAL', 'NO OFICIAL')
GROUP BY t.etapa_pandemia, g.cole_naturaleza;
```

Interpretación: en 2020-2021 el sector no oficial promedia 273,24 pts (266.576 evaluados) y el oficial 240,24 pts (820.068): una diferencia de 33,00 pts (CM 2.1).

9.4. Dice (Vista 4; también Vista 2)

Dimensiones y medidas: `dim_geografia` (zona y sector) × `dim_acceso_digital` (horas de internet); puntaje global, evaluados y tasa de riesgo. **Nivel y filtros:** Combinación de filtros sobre varias dimensiones: zona = rural y sector = oficial. En la Vista 2 el dice combina etapa, calendario y estrato (CM 2.2). **Procedimiento:** Se intersectan los filtros y se agrupa por horas de dedicación a internet.

```
SELECT d.estu_dedicacioninternet AS dedicacion,
       SUM(f.num_evaluados) AS n,
       ROUND(CAST(SUM(f.suma_punt_global) AS REAL) / SUM(f.num_evaluados), 2) AS prom_global,
       ROUND(CAST(SUM(f.eval_riesgo_bajo) AS REAL) * 100.0 / SUM(f.num_evaluados), 2) AS
pct_riesgo
FROM fact_resultados_saber11 f
JOIN dim_acceso_digital d ON f.id_digital = d.id_digital
JOIN dim_geografia g ON f.id_geografia = g.id_geografia
WHERE g.cole_area_ubicacion = 'RURAL' AND g.cole_naturaleza = 'OFICIAL'
GROUP BY d.estu_dedicacioninternet
ORDER BY 1;
```

Interpretación: en colegios oficiales rurales, quienes no navegan (78.542 evaluados) promedian 217,43 pts con 58,74 % en riesgo (< 220 pts), frente a 244,18 pts y 27,65 % entre quienes navegan más de 3 horas (68.912 evaluados). Se usa en el CM 4.2.

9.5. Pivot (Vista 3)

Dimensiones y medidas: `dim_socioeconomica` (escolaridad del padre) × `dim_acceso_digital` (computador); puntaje global. **Nivel y filtros:** Modo 1 del selector: escolaridad de los padres (filas) × tenencia de computador (columnas). Los modos 2 y 3 rotan a estrato × perfil TIC y escolaridad × género. **Procedimiento:** La consulta devuelve las combinaciones y la aplicación las dispone como matriz de doble entrada; el cambio de modo rota los ejes.

```
SELECT s.grupo_educacion_padre AS educacion,
       d.fami_tienecomputador,
       ROUND(CAST(SUM(f.suma_punt_global) AS REAL) / SUM(f.num_evaluados), 2) AS prom_global
FROM fact_resultados_saber11 f
JOIN dim_socioeconomica s ON f.id_socioeconomico = s.id_socioeconomico
JOIN dim_geografia g ON f.id_geografia = g.id_geografia
JOIN dim_acceso_digital d ON f.id_digital = d.id_digital
GROUP BY s.grupo_educacion_padre, d.fami_tienecomputador;
```

Interpretación: los estudiantes con padres de formación técnica o tecnológica y sin computador promedian 251,56 pts, 8,12 pts más que quienes tienen padres con básica primaria o ninguna escolaridad y sí tienen computador (243,44 pts) (CM 3.1).

10. Vistas interactivas de la aplicación Flask

La sección **Análisis multidimensional** se agrega al menú de la aplicación y reúne: el propósito de la etapa, la relación con los conocimientos evidentes, el diagrama del modelo estrella, la descripción de dimensiones, medidas y jerarquías, las cuatro vistas, la explicación de las operaciones, y los conocimientos, limitaciones y conclusiones. Todos los indicadores, gráficas y matrices se generan con consultas al modelo; los filtros actualizan los resultados y muestran la selección activa. La fuente (ICFES) y la cobertura (2019-1 a 2025-2) se indican en cada vista.

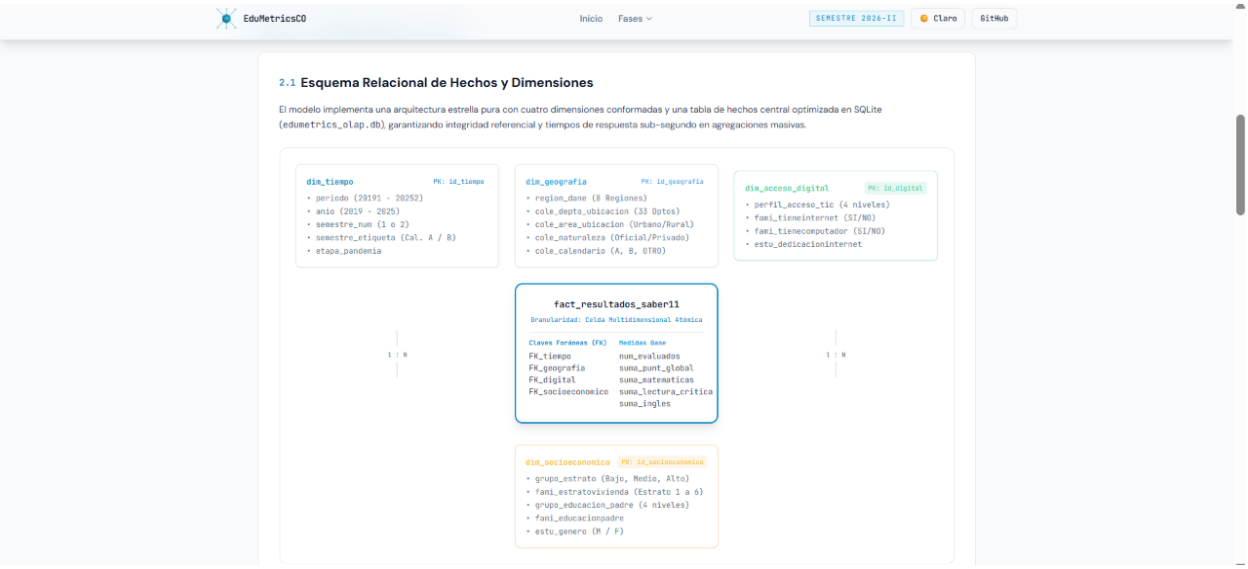


Figura 2. *Esquema relacional de hechos y dimensiones dentro de la aplicación (sección 2.1 de /etapa5).*

10.1. Vista 1 · Desagregación territorial y brecha digital

Pregunta	¿Cómo varía la penalización por exclusión digital sobre el puntaje global y de matemáticas al desagregar desde las regiones hacia los departamentos y las zonas urbano-rurales?
Dimensiones y medidas	Geografía (región, departamento, zona) × Acceso digital (perfil TIC). Medidas: Puntaje global y de matemáticas, brecha neta, pérdida relativa (%), evaluados
Jerarquía y operaciones	Territorial: región → departamento → zona. Operaciones: Roll-up y drill-down
3 indicadores	• Evaluados analizados: 4.541.652 • Puntaje global ponderado: 252,42 pts • Brecha digital territorial: 31,91 pts en Regiones, 31,55 en Departamentos y 31,75 en Zona
2 visualizaciones	1. Barras: puntaje global vs. matemáticas por territorio 2. Barras apiladas: distribución (%) de perfiles TIC por territorio
Matriz	Territorio × perfil TIC (Acceso pleno, Móvil, Offline, Exclusión absoluta), con brecha neta y pérdida relativa (%)

Filtros y controles	Periodo (dimensión tiempo: consolidado, 2025-2, 2023-2, 2021-2, 2019-2) y Sector del colegio (dimensión geografía: todos, oficial, no oficial). Botones Regiones (roll-up), Departamentos (drill-down) y Zona urbano/rural (detalle); recuadro “Consulta SQL en tiempo real” con el nivel activo y el número de filas
Interpretación	El promedio regional va de 277,58 pts en Bogotá a 236,42 pts en el Caribe. Dentro del Caribe, el grupo con acceso pleno promedia 261,56 pts y el de exclusión absoluta 222,61 pts (brecha de 38,95 pts, 14,9 % del puntaje del grupo pleno). Los porcentajes de perfil usan como denominador la población evaluada de cada territorio, por lo que cada fila suma 100 %. (Conocimientos: CM 1.1 y CM 1.2.)
Limitación y decisión	La clasificación regional no separa el nivel socioeconómico de la familia, que puede confundir la comparación; tampoco hay datos de calidad de la conexión. Territorializar los subsidios de conectividad hacia los departamentos y zonas con mayor exclusión, verificándolos con el drill-down.

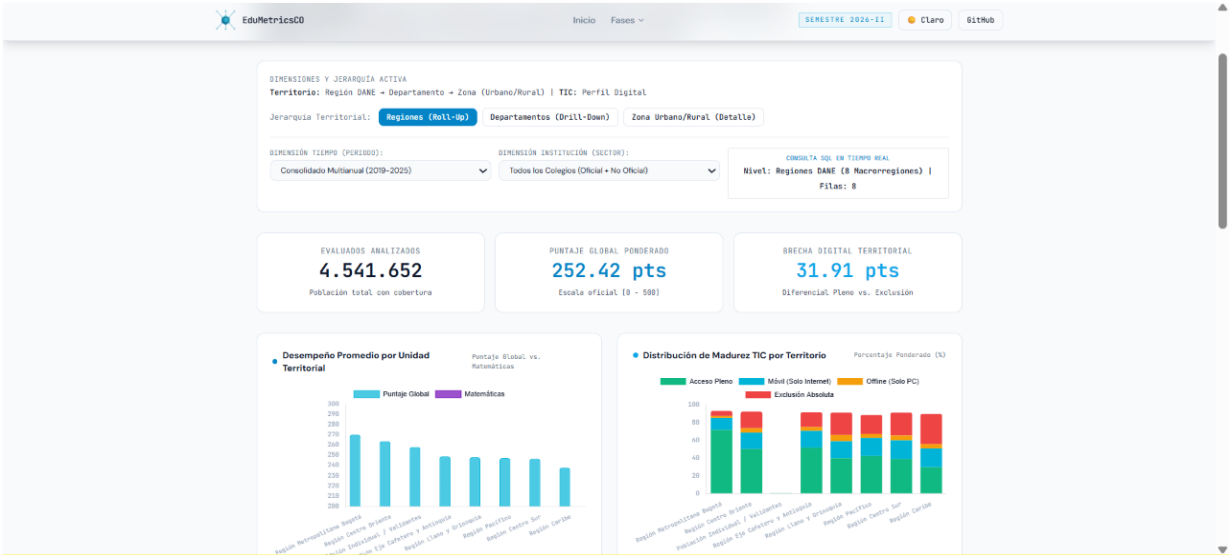


Figura 3. *Vista 1 en el nivel Regiones (roll-up): jerarquía territorial, filtros de periodo y sector, indicadores y gráficas.*

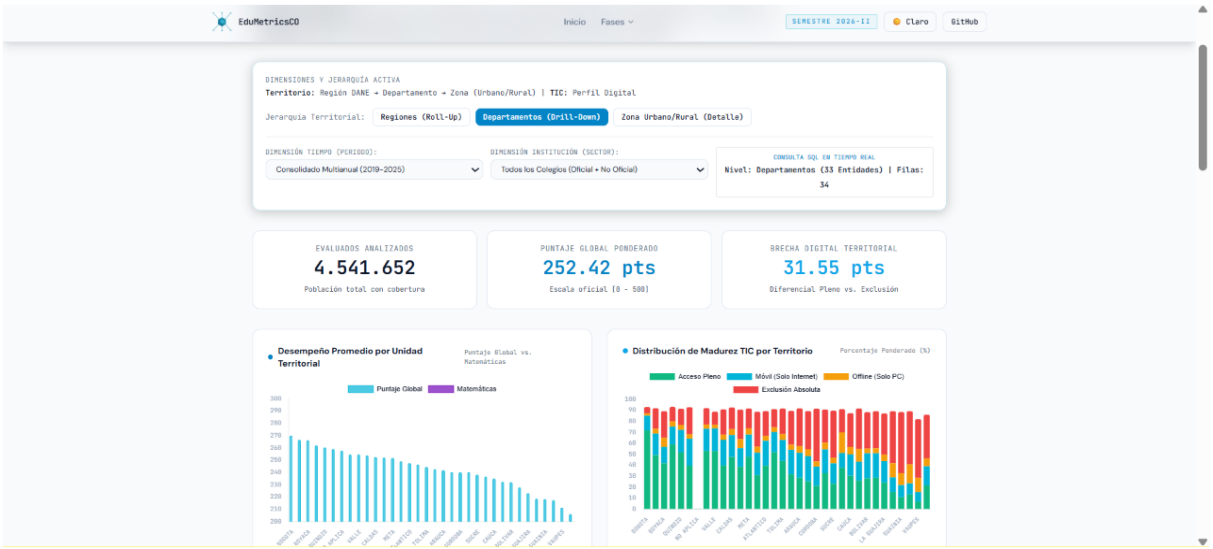


Figura 4. *Vista 1 en el nivel Departamentos (drill-down), con 33 entidades.*

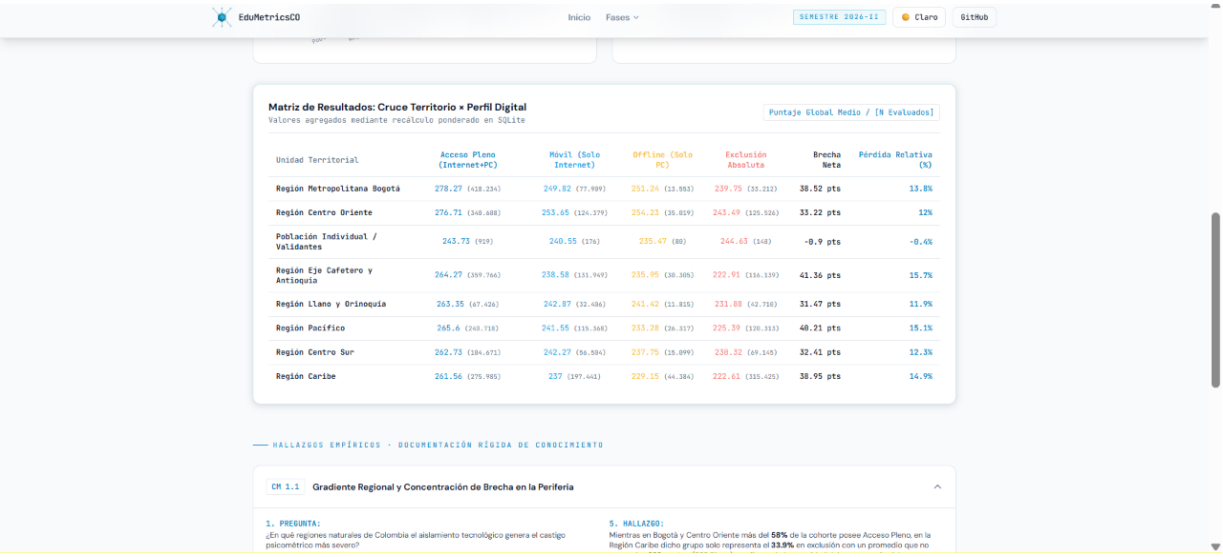


Figura 5. *Vista 1: matriz Territorio × Perfil digital por región, con brecha neta y pérdida relativa (%).*

10.2. Vista 2 · Dinámica temporal pre, durante y post-pandemia

Pregunta	¿Cómo evolucionó la brecha de rendimiento entre colegios públicos y privados a través de las etapas pre, durante y post-pandemia, y qué papel jugó la disponibilidad de hardware?
Dimensiones y medidas	Tiempo (etapa, año, periodo) × Geografía (naturaleza) × Acceso digital (computador). Medidas: Puntaje global, brecha oficial–no oficial, diferencial de hardware, evaluados
Jerarquía y operaciones	Temporal: etapa → año → periodo. Operaciones: Slice y dice
3 indicadores	• Evaluados en subcubo: 4.541.655 (consolidado) • Brecha privado vs. oficial: 29,32 pts en el consolidado, ponderada por evaluados (33,00 pts con el slice de confinamiento) • Tenencia de PC en el sector oficial: 47,9 %
2 visualizaciones	1. Líneas: puntaje global 2019-1 a 2025-2, oficial vs. no oficial 2. Barras agrupadas: efecto del hardware por etapa (con PC vs. sin PC)
Matriz	Etapa de pandemia × Oficial con PC | Oficial sin PC | No oficial con PC | No oficial sin PC | Brecha de hardware
Filtros y controles	Etapa de pandemia (tiempo), Calendario A/B (geografía) y Estrato bajo/medio/alto (socioeconómica). Botones de slice por etapa (todas, pre-pandemia, confinamiento, post-pandemia) y dos listas de dice (calendario y estrato); el recuadro “Subcubo dice recalculado” muestra el corte activo y su N
Interpretación	La diferencia entre colegios no oficiales y oficiales pasó de 25,24 pts en 2019 a 33,00 pts en 2020-2021. En ese cambio el promedio no oficial subió (265,80 → 273,24) y el oficial se mantuvo (240,56 → 240,24). Dentro del sector oficial en pandemia, quienes tienen computador promedian 251,88 pts y quienes no, 228,26 pts. La matriz por etapa muestra, para el sector oficial, 252,28 / 251,88 / 259,31 pts con computador y 229,84 / 228,26 / 237,60 sin él (pre, confinamiento y post-pandemia). Como los calendarios A y B se concentran en semestres distintos, la comparación se hace por etapa o año. (Conocimientos: CM 2.1 y CM 2.2.)
Limitación y decisión	En 2020-1 bajó la presentación de colegios vulnerables, lo que puede introducir sesgo de supervivencia; tampoco se conoce el uso pedagógico del equipo. Dimensionar el rezago acumulado del sector oficial para planes de recuperación y revisar la dotación de equipos.

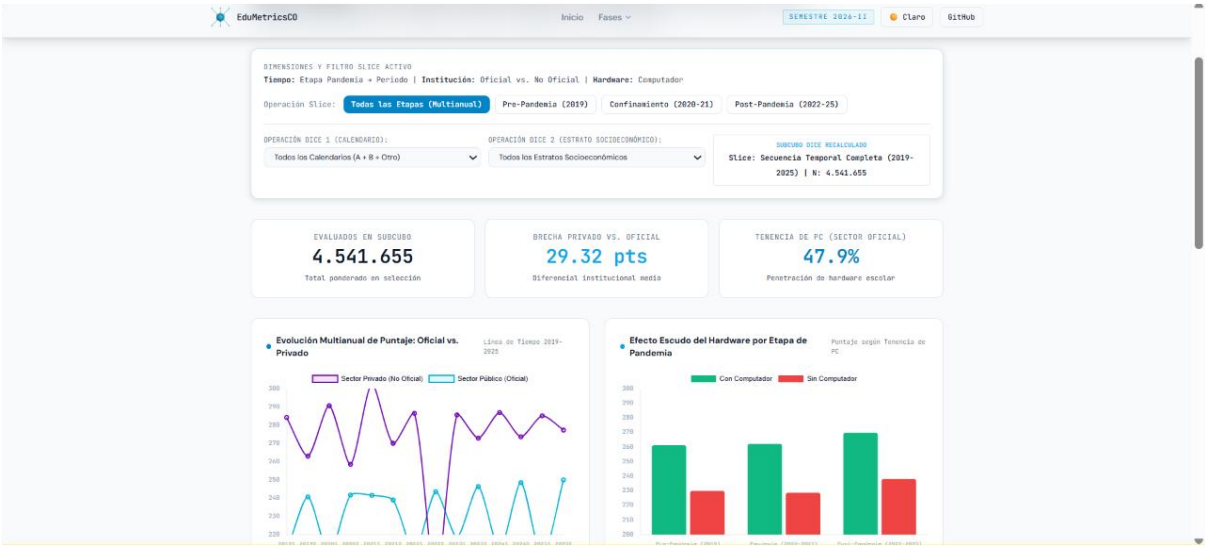


Figura 6. *Vista 2 con todas las etapas: filtros de slice y dice, indicadores y gráficas.*

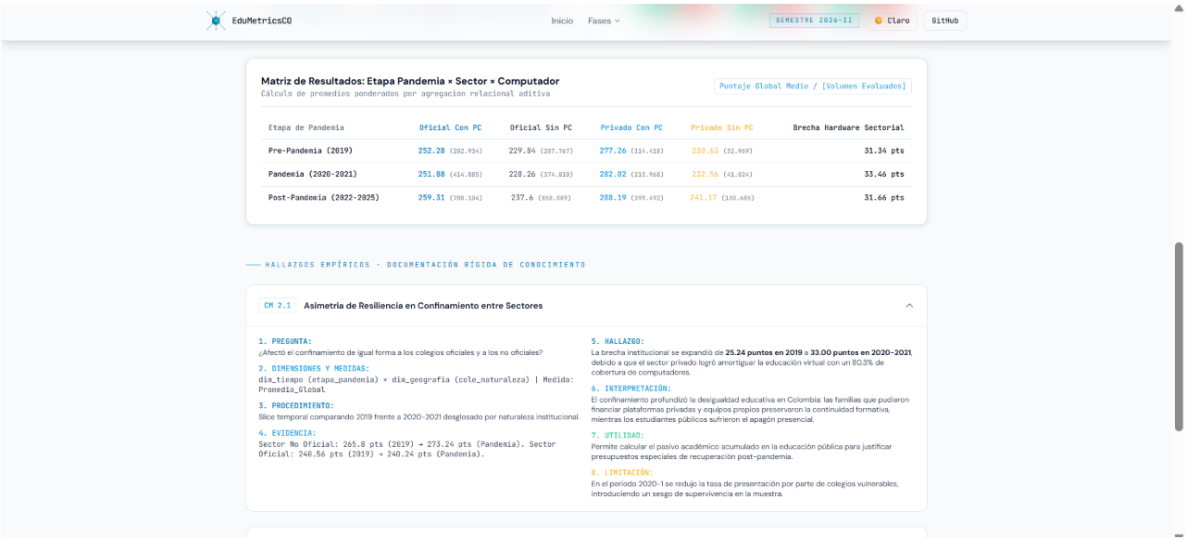


Figura 7. *Vista 2: matriz Etapa de pandemia × Sector × Computador y ficha del CM 2.1.*

10.3. Vista 3 · Capital cultural y brecha de hardware

Pregunta	¿En qué medida la disponibilidad de computador compensa o amplifica las desventajas de origen asociadas a la baja escolaridad parental?
Dimensiones y medidas	Socioeconómica (escolaridad, estrato, género) × Acceso digital (computador). Medidas: Puntaje por competencia (lectura, matemáticas, ciencias), diferencial de hardware, evaluados
Jerarquía y operaciones	Capital cultural: grupo educativo → nivel; estratificación: grupo → estrato. Operaciones: Pivot
3 indicadores	• Evaluados seleccionados: 4.541.655 • Media en lectura crítica: 53,08 pts • Ventaja parental mitigadora: 8,12 pts (técnicos sin PC frente a primaria con PC)
2 visualizaciones	1. Barras agrupadas: puntaje con y sin computador por escolaridad del padre 2. Barras agrupadas: lectura, matemáticas y ciencias naturales según escolaridad
Matriz	Matriz pivot: escolaridad parental (filas) × tenencia de computador (columnas), con diferencial entre extremos
Filtros y controles	Zona (geografía: todas, urbana, rural) y Género (socioeconómica: todos, F, M). Selector de rotación de ejes (pivot) con tres modos: Educación × PC, Estrato × Perfil TIC y Educación × Género
Interpretación	Con padres de básica primaria o ninguna escolaridad, el puntaje es 243,44 pts con computador y 226,83 pts sin él (+16,61 pts); con padres de superior y posgrado, 294,03 y 249,32 pts (+44,71 pts). La diferencia asociada al computador es mayor cuando los padres tienen más escolaridad, por lo que los datos no muestran que el computador compense más en los hogares de menor escolaridad. La categoría “No sabe / No informa” (19,99 %) se muestra aparte. En la matriz Estrato × Perfil digital, la diferencia entre acceso pleno y exclusión absoluta es de 29,5 pts en estratos bajos, 57,8 en medios y 98,05 en altos. (Conocimientos: CM 3.1 y CM 3.2.)
Limitación y decisión	La escolaridad parental es autorreportada y el computador coincide con otras ventajas del hogar. Combinar la entrega de equipos con capacitación y guías de acompañamiento familiar.

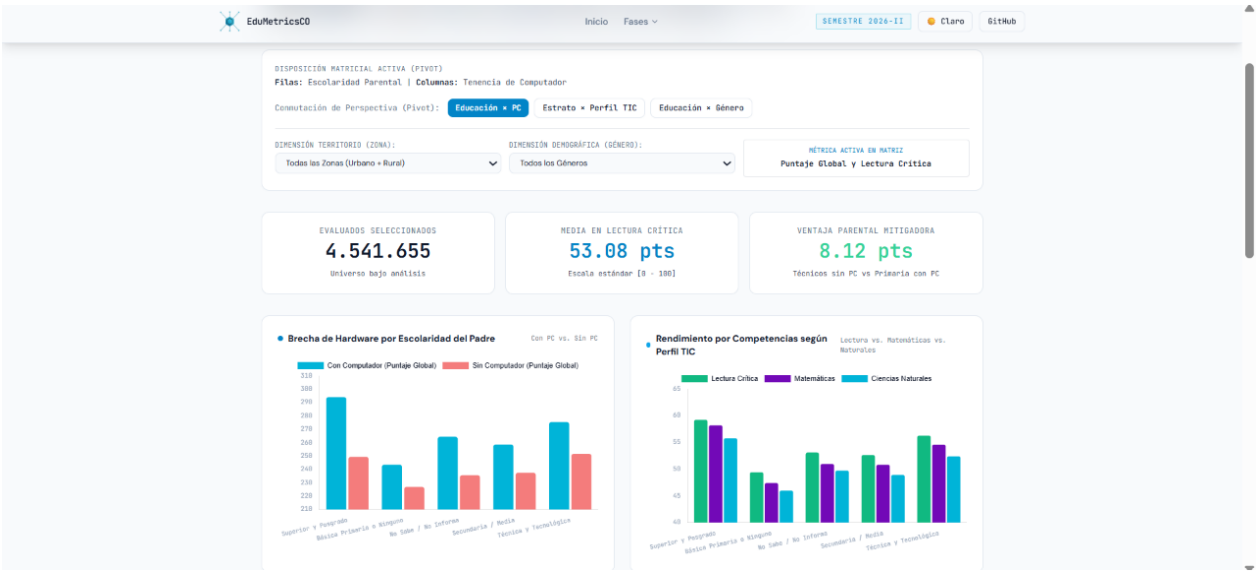


Figura 8. *Vista 3 en el modo Educación × PC: filtros de zona y género, indicadores y gráficas.*

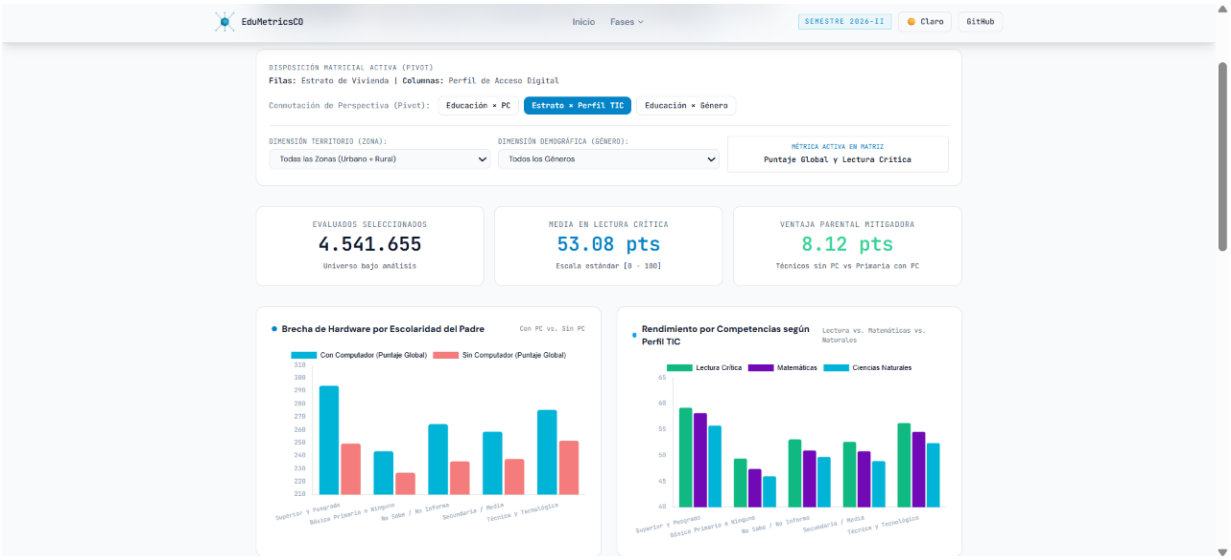


Figura 9. *Vista 3 rotada al modo Estrato × Perfil TIC (operación pivot).*

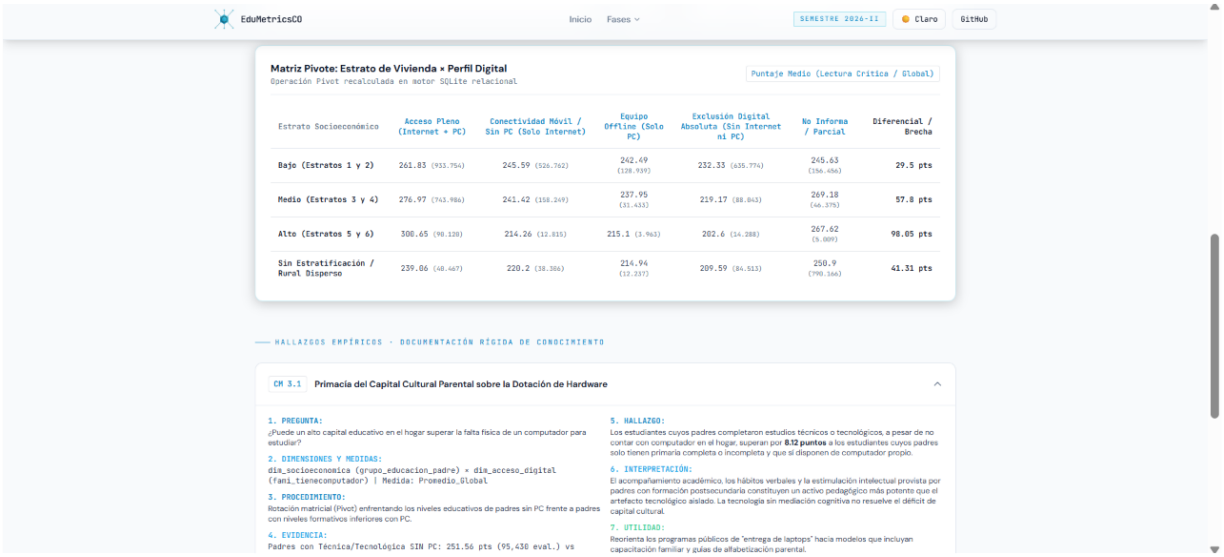


Figura 10. *Vista 3: matriz pivot Estrato × Perfil digital y ficha del CM 3.1.*

Escolaridad del padre	**Diferencial por computador (pts)**	**Lectura de la matriz**
Superior y posgrado	44,71	mayor
Básica primaria o ninguna	16,61	menor
No sabe / No informa	28,89	—
Secundaria / media	21,15	—
Técnica y tecnológica	23,78	—

10.4. Vista 4 · Hábitos de uso de internet, bilingüismo y riesgo académico

Pregunta	¿Cuál es el umbral de dedicación diaria a internet a partir del cual el uso de la red deja de favorecer el dominio del inglés y comienza a incrementar el riesgo de bajo rendimiento global?
Dimensiones y medidas	Acceso digital (horas de internet) × Geografía (zona) × Socioeconómica (estrato). Medidas: Puntaje de inglés, tasa de bilingüismo, tasa de riesgo crítico, tasa de alto rendimiento
Jerarquía y operaciones	Acceso digital: perfil TIC → internet/computador → horas de dedicación. Operaciones: Drill-down en horas de navegación y dice multivariable
3 indicadores	• Evaluados analizados: 4.541.655 • Tasa bilingüe (B1/B+): 11,5 % • Tasa en riesgo crítico (< 220 pts): 30,1 %
2 visualizaciones	1. Barras y línea: horas de internet vs. puntaje de inglés y % bilingüe 2. Dona: distribución por nivel de riesgo (bajo, medio, alto)
Matriz	Horas de dedicación (No navega, 30 min o menos, 30–60 min, 1–3 h, más de 3 h y No informa) × evaluados, puntaje global, puntaje de inglés, % bilingüe y % riesgo
Filtros y controles	Zona (geografía: todas, urbana, rural) y Estrato (socioeconómica: todos, bajos 1–2, medios 3–4, altos 5–6, sin estratificación). Métrica protagonista (Competencia en inglés, Concentración de riesgo, Puntaje global integral) y drill-down por tramos de horas de navegación
Interpretación	La tasa de riesgo baja de 53,83 % entre quienes no navegan a 22,76 % con 1–3 horas y 21,17 % con más de 3 horas; el bilingüismo sube de 2,94 % a 14,87 % y 17,91 %. La mayor parte de la mejora ocurre entre no navegar y 1–3 horas, y a partir de ahí se estabiliza. Los denominadores son `eval_ingles_presente` para bilingüismo y `num_evaluados` para riesgo; el grupo "No informa" (933.672 evaluados) se muestra aparte. (Conocimientos: CM 4.1 y CM 4.2.)
Limitación y decisión	No se distingue el tipo de actividad durante la conexión (estudio u ocio) y no se conoce la deserción previa a grado 11. Priorizar conectividad y recursos de aprendizaje en las zonas oficiales rurales sin conexión, donde se concentra el riesgo.

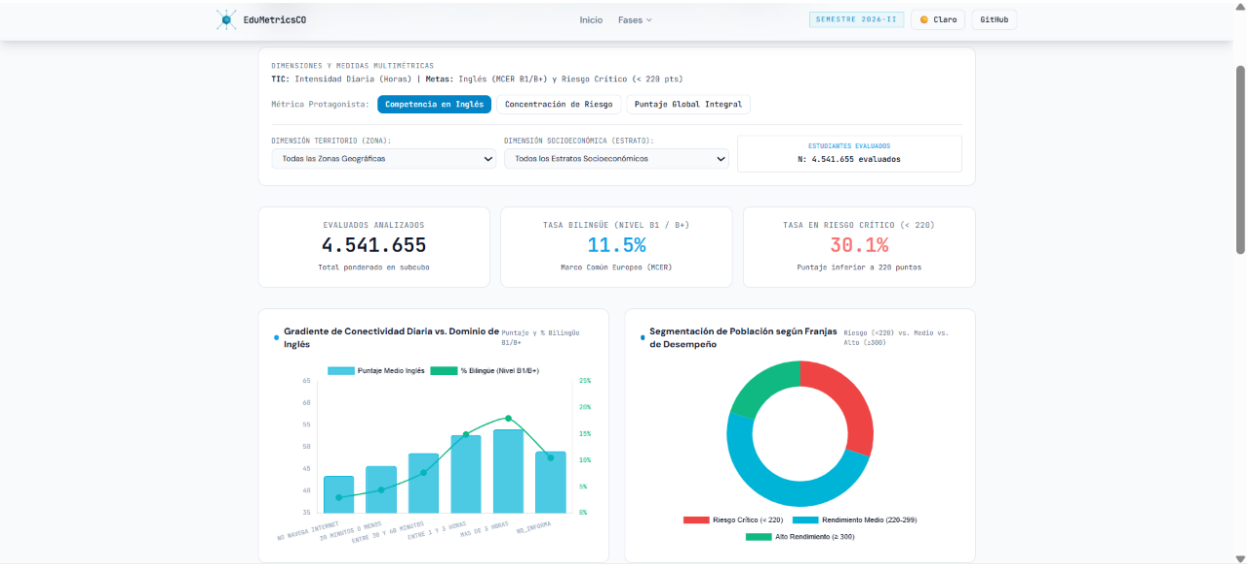


Figura 11. *Vista 4 con la métrica Competencia en inglés: gradiente de dedicación a internet y distribución por franjas de desempeño.*

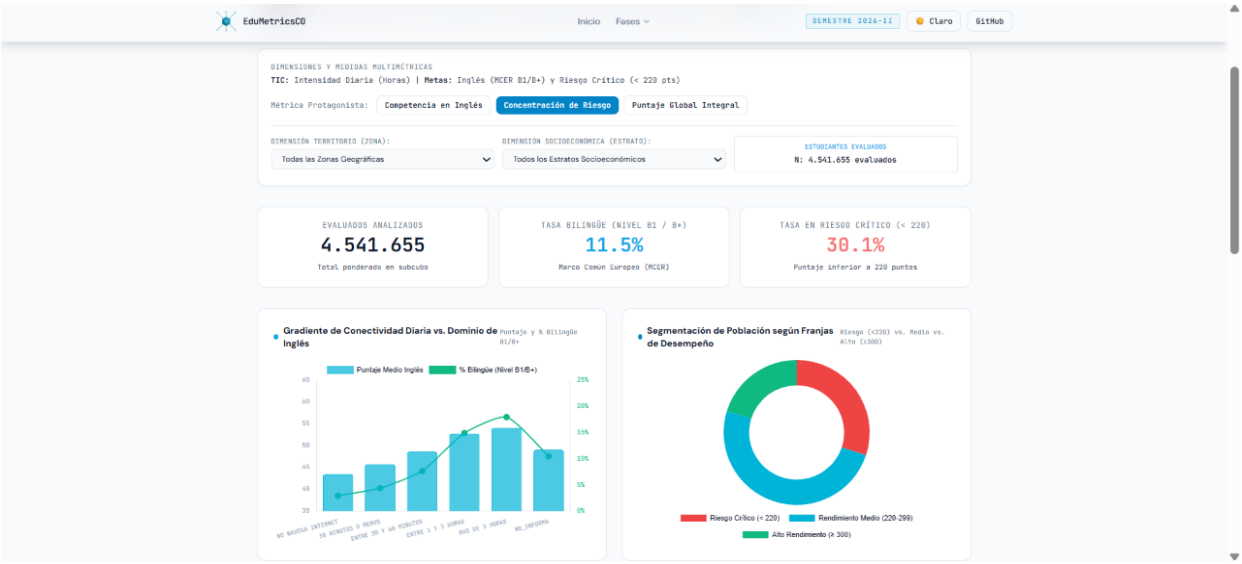


Figura 12. *Vista 4 con la métrica Concentración de riesgo.*

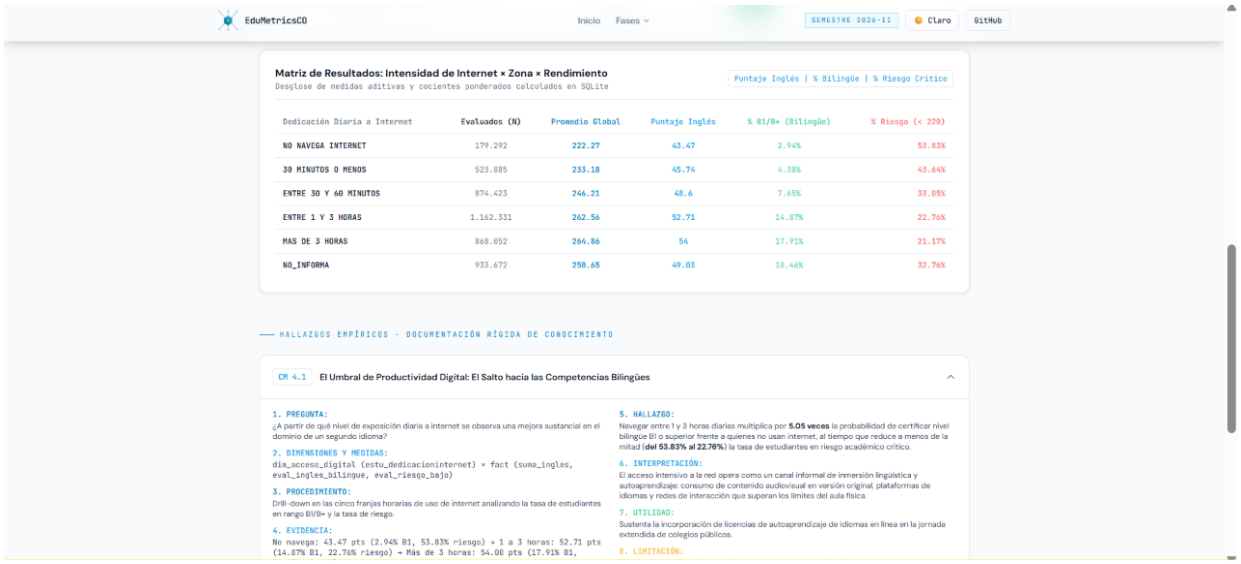


Figura 13. *Vista 4: matriz de dedicación diaria con puntajes y tasas de bilingüismo y de riesgo.*

Denominadores. El porcentaje de cada perfil TIC (Vista 1) se calcula sobre los evaluados del territorio y la pérdida relativa sobre el puntaje del grupo con acceso pleno del mismo territorio. En la Vista 4, la tasa de bilingüismo usa como denominador a quienes presentaron inglés (`eval_ingles_presente`) y la tasa de riesgo a todos los evaluados del grupo de horas de navegación. Al cambiar de nivel, los porcentajes y promedios se recalculan con sus propias sumas; nunca se promedian porcentajes entre grupos.

11. Ocho conocimientos multidimensionales

Cada conocimiento se documenta con los ocho elementos de la guía y coincide con la ficha de su vista en la aplicación. Las afirmaciones se formulan como asociaciones observadas; las explicaciones que los datos no permiten comprobar se presentan como hipótesis.

CM 1.1 · Vista 1 · Gradiente regional y concentración de brecha en la periferia

1. Pregunta	¿En qué regiones naturales de Colombia el aislamiento tecnológico se asocia con la diferencia de puntaje más grande?
2. Dimensiones y medidas	`dim_geografia.region_dane` × `dim_acceso_digital.perfil_acceso_tic`; medidas: puntaje global promedio ponderado y evaluados.
3. Procedimiento	Roll-up a las 8 regiones DANE y diferencia neta entre el perfil de acceso pleno y el de exclusión absoluta. Filtros y nivel: Nivel de agrupación = Región natural (roll-up); Zona = Todas; Periodo = Consolidado histórico. Denominador de los porcentajes: evaluados de la región.
4. Evidencia	Vista 1: matriz Territorio × Perfil TIC y gráfica de barras (consulta de la sección 9.2 y consulta por perfil de acceso en la región Caribe).
5. Hallazgo	En la región Caribe el grupo con acceso pleno promedia 261,56 pts (275.985 evaluados, 26,8 % de la región) y el de exclusión absoluta 222,61 pts (315.425 evaluados, 30,6 %): una brecha de 38,95 pts, equivalente a 14,9 % del puntaje del grupo pleno. A nivel regional, Bogotá promedia 277,58 pts, Centro Oriente 259,45 pts y el Caribe 236,42 pts.
6. Interpretación frente al conocimiento evidente	La brecha digital no es homogénea entre regiones: en el Caribe tres de cada diez evaluados están en exclusión absoluta y su promedio es 38,95 pts menor que el de sus pares con acceso pleno. Frente al CE 2.1 (brecha urbano–rural de 24,3 pts), este cruce mide la diferencia dentro de la región según el acceso. Que en las regiones periféricas la falta de conectividad coexista con otras desventajas de infraestructura es una hipótesis.
7. Utilidad	Territorializar los subsidios de conectividad hacia los territorios con mayor exclusión (la ficha de la app propone Magdalena, La Guajira, Chocó y Córdoba), verificándolos con el drill-down departamental.
8. Limitación	La clasificación regional no discrimina el nivel socioeconómico de la familia, que actúa como variable de confusión; la asociación no es causal.

CM 1.2 · Vista 1 · Disrupción del patrón rural en Cundinamarca y Boyacá (drill-down departamental)

1. Pregunta	¿Se mantiene la desventaja rural cuando los estudiantes cuentan con hardware e internet en el centro del país?
2. Dimensiones y medidas	`dim_geografia` (`cole_depto_ubicacion`, `cole_area_ubicacion`) × `dim_acceso_digital`; medida: puntaje global promedio (y matemáticas).
3. Procedimiento	Drill-down a Cundinamarca, cruzando zona urbana frente a rural con perfil TIC = acceso pleno; y, como contraste, zona rural con exclusión absoluta por departamento. Filtros y nivel: Nivel = Departamento (drill-down); Región = Centro Oriente / Cundinamarca; Perfil TIC = Acceso pleno.
4. Evidencia	Vista 1: nivel Departamento con los filtros indicados; matriz Territorio × Perfil TIC.
5. Hallazgo	Con acceso pleno, la zona rural de Cundinamarca promedia 288,45 pts (32.825 evaluados) y la urbana 268,67 pts (124.067): 19,78 pts a favor de la rural. En contraste, en zona rural con exclusión absoluta el promedio de matemáticas es 36,85 pts en Vaupés, 37,38 en Chocó y 39,40 en La Guajira, frente a 49,10 en Cundinamarca y 50,22 en Boyacá; en Cundinamarca rural, el perfil de acceso pleno tiene 59,01 pts en matemáticas (+9,91) y 288,45 en el global (+50,76), y la tasa de riesgo baja de 35,54 % a 11,40 %.

6. Interpretación frente al conocimiento evidente	La desventaja rural no es uniforme: en Cundinamarca el grupo rural con acceso pleno supera al urbano, y en departamentos periféricos el grupo rural sin acceso tiene los promedios más bajos. Frente al CE 2.1 y 2.2, que trataban lo rural como un bloque, el drill-down separa territorios. Que la etiqueta "rural" incluya colegios campestres privados cerca de Bogotá es una hipótesis que esta consulta no comprueba (no se cruza con el carácter oficial del colegio).
7. Utilidad	Desagregar los colegios rurales públicos de los privados campestres antes de diagnosticar el campo, y priorizar recursos en las zonas rurales de los departamentos periféricos.
8. Limitación	El fenómeno se restringe a departamentos con conurbación metropolitana; no se reproduce en Chocó, Guaviare o Vaupés. La asociación no es causal.

CM 2.1 · Vista 2 · Asimetría de resiliencia en confinamiento entre sectores

1. Pregunta	¿Cambió de igual forma el puntaje de los colegios oficiales y de los no oficiales durante el confinamiento?
2. Dimensiones y medidas	`dim_tiempo.etapa_pandemia` × `dim_geografia.cole_naturaleza`; medida: puntaje global promedio.
3. Procedimiento	Slice temporal que compara 2019 con 2020-2021, agrupado por naturaleza del colegio. Filtros: etapa_pandemia en (Pre-pandemia 2019; Confinamiento y pandemia 2020-2021); agrupado por cole_naturaleza.
4. Evidencia	Vista 2: gráfica de líneas oficial vs. no oficial y matriz por etapa (consulta de la sección 9.3).
5. Hallazgo	El sector no oficial pasó de 265,80 pts (2019) a 273,24 pts (pandemia) y el oficial de 240,56 a 240,24 pts. La brecha pasó de 25,24 pts en 2019 a 33,00 pts en 2020-2021, un aumento de 7,76 pts.
6. Interpretación frente al conocimiento evidente	La brecha se amplió porque el promedio no oficial subió y el oficial se mantuvo. La Etapa 4 (CE 3.1), basada en una muestra de calendario A, reportó una caída global de 6,7 pts; en el censo completo el promedio oficial no cae, por lo que la composición de la población pesa en la comparación. La ficha de la app atribuye la ampliación a que el sector privado amortiguó la educación virtual con mayor cobertura de computadores (80,3 %); es una hipótesis.
7. Utilidad	Calcular el rezago acumulado de la educación pública para sustentar presupuestos de recuperación.
8. Limitación	En 2020-1 se redujo la presentación de colegios vulnerables, lo que introduce un sesgo de supervivencia, sobre todo en el calendario B privado. No se puede atribuir el cambio solo a la pandemia.

CM 2.2 · Vista 2 · El efecto escudo del hardware en la educación oficial

1. Pregunta	¿Qué diferencia de puntaje hay, durante la pandemia, entre estudiantes de colegios públicos con y sin computador?
2. Dimensiones y medidas	`dim_tiempo.etapa_pandemia` × `dim_acceso_digital.fami_tienecomputador`, con `cole_naturaleza` = OFICIAL; medida: puntaje global promedio.
3. Procedimiento	Dice del subcubo de colegios oficiales en la etapa de pandemia, cruzado por tenencia de computador. Filtros: cole_naturaleza = OFICIAL y etapa_pandemia = Confinamiento y pandemia (2020-2021).
4. Evidencia	Vista 2: matriz de contingencia Etapa × sector × computador.
5. Hallazgo	En pandemia, los estudiantes de colegios oficiales con computador promedian 251,88 pts y los que no, 228,26 pts: una diferencia de 23,62 pts.
6. Interpretación frente al conocimiento evidente	La diferencia por computador dentro del sector oficial en pandemia (23,62 pts) es algo menor que la del conjunto de la población (CE 4.2, 28,4 pts), por lo que el cruce confirma que persiste

	en pandemia, sin mostrar por sí solo una diferencia propia de esa etapa. Que el computador haya facilitado la continuidad pedagógica remota es una hipótesis.
7. Utilidad	Aportar evidencia técnica para programas de dotación de computadores a estudiantes de colegios oficiales.
8. Limitación	No se evalúan las competencias digitales de los docentes ni el uso pedagógico del equipo en el hogar; el hogar con computador puede tener otras ventajas.

CM 3.1 · Vista 3 · Primacía del capital cultural parental sobre la dotación de hardware

1. Pregunta	¿Puede un alto capital educativo en el hogar asociarse con mejores puntajes aun sin computador?
2. Dimensiones y medidas	`dim_socioeconomica.grupo_educacion_padre` × `dim_acceso_digital.fami_tienecomputador`; medida: puntaje global promedio.
3. Procedimiento	Pivot con escolaridad de los padres en filas y tenencia de computador en columnas; se contrasta padres con formación técnica o tecnológica sin computador frente a padres con primaria o ninguna con computador. Filtros: Pivot = fila grupo_educacion_padre, columna fami_tienecomputador; métrica prom_global.
4. Evidencia	Vista 3: matriz pivot y gráfica de barras agrupadas (consulta de la sección 9.5).
5. Hallazgo	Los estudiantes con padres de formación técnica o tecnológica y sin computador promedian 251,56 pts (95.430 evaluados), 8,12 pts más que los de padres con primaria o ninguna escolaridad que sí tienen computador (243,44 pts; 372.055). Además, el diferencial por computador es de 16,61 pts con padres de primaria o ninguna (243,44 con computador, 226,83 sin él; 640.203 evaluados) y de 44,71 pts con padres de superior y posgrado (294,03 y 249,32 pts).
6. Interpretación frente al conocimiento evidente	En esta comparación, la escolaridad de los padres se asocia con puntajes más altos que la tenencia de computador, y la diferencia por computador es mayor en los hogares de mayor escolaridad, por lo que los datos no muestran que el computador compense más donde la escolaridad es baja. Explicarlo por el acompañamiento académico familiar es una hipótesis.
7. Utilidad	Reorientar los programas de entrega de computadores hacia modelos que incluyan capacitación y guías de acompañamiento para las familias.
8. Limitación	El autorreporte no mide el tiempo real que los padres dedican a las tareas; el 19,99 % de las respuestas es “No sabe”, que se mantiene como categoría aparte.

CM 3.2 · Vista 3 · Vulnerabilidad asimétrica por competencias: lectura crítica frente a matemáticas

1. Pregunta	¿Se asocia la falta de computador de la misma forma con las habilidades verbales y con las cuantitativas?
2. Dimensiones y medidas	`dim_acceso_digital` × `dim_socioeconomica`; medidas: puntaje promedio de lectura crítica y de matemáticas (suma_lectura_critica, suma_matematicas sobre num_evaluados).
3. Procedimiento	Comparación de promedios ponderados por área entre estudiantes con y sin computador. Filtros: grupo_educacion_padre = Superior y Posgrado, contrastando fami_tienecomputador = SI/NO.
4. Evidencia	Vista 3: gráfica de barras de competencias por escolaridad.
5. Hallazgo	Con padres de superior y posgrado, quienes tienen computador promedian 60,47 pts en lectura y 59,70 en matemáticas; quienes no, 52,72 y 50,43. La diferencia es de 9,27 pts en matemáticas y de 7,75 pts en lectura crítica: 19,6 % mayor en matemáticas.
6. Interpretación frente al conocimiento evidente	En este grupo, la diferencia asociada a no tener computador es mayor en matemáticas que en lectura crítica. Una posible explicación (hipótesis) es que el razonamiento cuantitativo depende

	más de software y simuladores, mientras que la lectura puede ejercitarse con material impreso. Esto matiza el CE 4.2, que solo usaba el puntaje global.
7. Utilidad	Orientar el uso de las salas de informática hacia el refuerzo de matemáticas y ciencias.
8. Limitación	No se controla la intensidad horaria de cada asignatura en los planes de estudio; la comparación es para un solo grupo de escolaridad y no es causal.

CM 4.1 · Vista 4 · Umbral de productividad digital y competencias bilingües

1. Pregunta	¿A partir de qué nivel de exposición diaria a internet se observa una mejora sustancial en el dominio del inglés?
2. Dimensiones y medidas	`dim_acceso_digital.estu_dedicacioninternet` × medidas del hecho: `suma_ingles`, `eval_ingles_bilingue`, `eval_ingles_presente` y `eval_riesgo_bajo`.
3. Procedimiento	Drill-down en las cinco franjas de uso de internet, con la tasa de estudiantes en nivel B1/B+ (denominador: quienes presentaron inglés) y la tasa de riesgo (denominador: total de evaluados de la franja). Agregación nacional consolidada.
4. Evidencia	Vista 4: gráfica de barras y línea y matriz de dedicación diaria (consulta de la sección 9.4 para el subcubo rural oficial).
5. Hallazgo	No navega: 43,47 pts de inglés, 2,94 % B1/B+ y 53,83 % en riesgo. 1 a 3 horas: 52,71 pts, 14,87 % y 22,76 %. Más de 3 horas: 54,00 pts, 17,91 % y 21,17 %. La tasa de bilingüismo de 1 a 3 horas es 5,05 veces la de quienes no navegan.
6. Interpretación frente al conocimiento evidente	El mayor salto ocurre entre no navegar y navegar de 1 a 3 horas; de 1–3 a más de 3 horas la mejora es pequeña. El CE 4.3 describía los extremos de la brecha; aquí se identifica en qué tramo cambian los indicadores. La razón es entre tasas de grupos, no una probabilidad individual. Explicarlo por inmersión lingüística informal es una hipótesis.
7. Utilidad	Sustentar la incorporación de plataformas de autoaprendizaje de idiomas en línea en la jornada extendida de colegios públicos.
8. Limitación	El indicador no distingue si el tiempo en internet es académico o recreativo, y los hogares con más acceso tienen otras ventajas; no es causal.

CM 4.2 · Vista 4 · Concentración de riesgo en la ruralidad oficial desconectada

1. Pregunta	¿Qué perfil institucional y geográfico acumula la mayor proporción de estudiantes por debajo de 220 puntos?
2. Dimensiones y medidas	`dim_geografia` (`cole_area_ubicacion` = RURAL, `cole_naturaleza` = OFICIAL) × `dim_acceso_digital`; medida: tasa de riesgo (eval_riesgo_bajo / num_evaluados).
3. Procedimiento	Dice que aísla las sedes oficiales rurales y cruza por franjas de dedicación a internet. Filtros: cole_area_ubicacion = RURAL AND cole_naturaleza = OFICIAL.
4. Evidencia	Vista 4: dona de riesgo y matriz de dedicación con zona = rural (consulta de la sección 9.4).
5. Hallazgo	En colegios oficiales rurales sin internet en casa (148.210 evaluados) el promedio es 220,65 pts y el 58,74 % está en riesgo, frente a 18,42 % en colegios oficiales urbanos con más de una hora de internet (3,2 veces). Entre quienes navegan más de 3 horas en el sector oficial rural el promedio es 244,18 pts y el riesgo 27,65 %.
6. Interpretación frente al conocimiento evidente	La combinación de ruralidad, sector oficial y desconexión concentra la mayor proporción de estudiantes bajo 220 pts: cerca de 6 de cada 10 en el grupo sin navegación. Frente al CE 2.2 (rural con poco acceso), aquí se cuantifica el riesgo en ese perfil. Que ello limite el acceso a educación superior es una inferencia, no un resultado de los datos.
7. Utilidad	Definir criterios técnicos de elegibilidad para programas de matrícula cero y becas en zonas rurales oficiales desconectadas (por ejemplo, PDET y ZOMAC).

8. Limitación	No se evalúa la deserción previa a grado 11, que en el campo puede sacar de la muestra a los perfiles de menor rendimiento; la asociación no es causal.

12. Limitaciones y decisiones sustentadas

Cada vista (sección 10) y cada conocimiento (sección 11) documentan su limitación y la decisión que sustenta. En conjunto: la clasificación regional no separa el nivel socioeconómico ni mide la calidad de la conexión; en 2020-1 hubo sesgo de supervivencia por la menor presentación de colegios vulnerables; la escolaridad parental es autorreportada y el 19,99 % respondió “No sabe”; y la intensidad de uso de internet no distingue entre actividad académica y recreativa. Las decisiones propuestas son: territorializar los subsidios de conectividad, dimensionar el rezago acumulado del sector oficial y financiar su dotación de equipos, acompañar la entrega de computadores con capacitación familiar, y priorizar plataformas de idiomas y criterios de elegibilidad para becas en zonas rurales oficiales desconectadas. Los resultados son asociaciones observadas y no demuestran causalidad.

13. Conclusiones

1. **Modelo viable:** el modelo estrella en SQLite permite consultar 4,54 millones de registros (717.225 filas de hechos) con tiempos de respuesta bajos y reproduce exactamente los conteos y promedios de los datos tratados (diferencia de 0 en las tres comprobaciones; 0 claves huérfanas y 0 duplicados).
2. **Territorio:** el promedio va de 277,58 pts en Bogotá a 236,42 pts en el Caribe, y dentro del Caribe el grupo en exclusión absoluta promedia 38,95 pts menos que el de acceso pleno. La desventaja rural no es uniforme: en Cundinamarca el grupo rural con acceso pleno supera al urbano en 19,78 pts.
3. **Sector y pandemia:** la brecha entre colegios no oficiales y oficiales pasó de 25,24 a 33,00 pts entre 2019 y 2020-2021, porque el promedio no oficial subió y el oficial se mantuvo. En el sector oficial, tener computador se asocia con 23,62 pts más en pandemia.
4. **Capital cultural:** estudiantes con padres técnicos o tecnólogos sin computador superan en 8,12 pts a los de padres con primaria que sí lo tienen; y la diferencia por computador es mayor con padres de superior y posgrado (44,71 pts) que con primaria (16,61 pts). En matemáticas la diferencia asociada a no tener computador (9,27 pts) supera a la de lectura (7,75 pts).
5. **Hábitos TIC:** el riesgo baja de 53,83 % (no navega) a 22,76 % (1–3 horas) y el bilingüismo sube de 2,94 % a 14,87 %, con poca mejora adicional después de 3 horas. En colegios oficiales rurales sin navegación, el 58,74 % está en riesgo.
6. **Alcance:** los resultados orientan la focalización de políticas de conectividad y dotación; afirmar efectos causales requeriría otros diseños de análisis.

14. Evidencias del trabajo en el repositorio

Repositorio público: https://github.com/Rockbayo/MD_Proyecto_Educacion · Rama: `feature/etapa-5` · Aplicación publicada: https://md-proyecto-educacion.onrender.com/

Contenido de la solución en el repositorio:

Artefacto	**Ruta**
Diagrama del modelo estrella	`static/assets/images/diagrama_estrella.png`
Diccionario del modelo multidimensional	`data/reports/Informe_Tecnico_Etapa5_Analisis_Multidimensional.md`
Creación de tablas y relaciones (DDL)	`scripts/07_modelo_estrella_olap.py` (función `crear_esquema_estrella()`)
Transformación y carga (ETL)	`scripts/07_modelo_estrella_olap.py` (funciones `poblar_dimensiones()` y `poblar_tabla_hechos_chunked()`)
Consultas de análisis y endpoints OLAP	`app.py` (rutas `/api/v1/olap/pregunta1` a `pregunta4`)
Base de datos OLAP	`data/processed/edumetrics_olap.db`
Reporte de validación	`data/reports/validacion_modelo_estrella.json`
Plantillas de la sección	`templates/etapa5/` (portal y vistas `pregunta1` a `pregunta4`)
Dependencias y ejecución	`README.md`, sección “Ejecución del Portal Web y Módulo OLAP (Etapa 5)”

14.1. Commits de la Etapa 5 por integrante

Integrante	**Commits**	**Identificadores y contenido**
Oscar Giovanni Robayo	8	2b6f996 (script del modelo estrella e imputación de estratos), 0bdf215 (reporte de validación), 205f16c (rutas Flask y endpoints), d71082f (plantillas de las vistas con Chart.js), a8abeef (vista principal y menú), c075a88 (informe técnico en Markdown y PDF), d0c51dd (ajuste de filtros OLAP), 0efddf7 (base OLAP para el despliegue). Fechas: 1 al 3 de noviembre de 2026.
Oscar Felipe Delgado	4	e94ce41 (etiquetas y tooltips de las operaciones OLAP), 1484693 (brecha relativa, efecto del hardware y razón de riesgo en la API), 7f47244 (nuevas métricas en las vistas y README), 986127b (informe técnico en PDF y trazabilidad en scripts). Fecha: 7 de noviembre de 2026.

Pull requests de la etapa: #25 (Feature/etapa 5) y #27 (informe técnico final), de Robayo, y #28 (Feature/etapa 5), de Delgado. Los commits de Robayo aparecen con los alias Rockbayo e INGOR (mismo correo institucional).

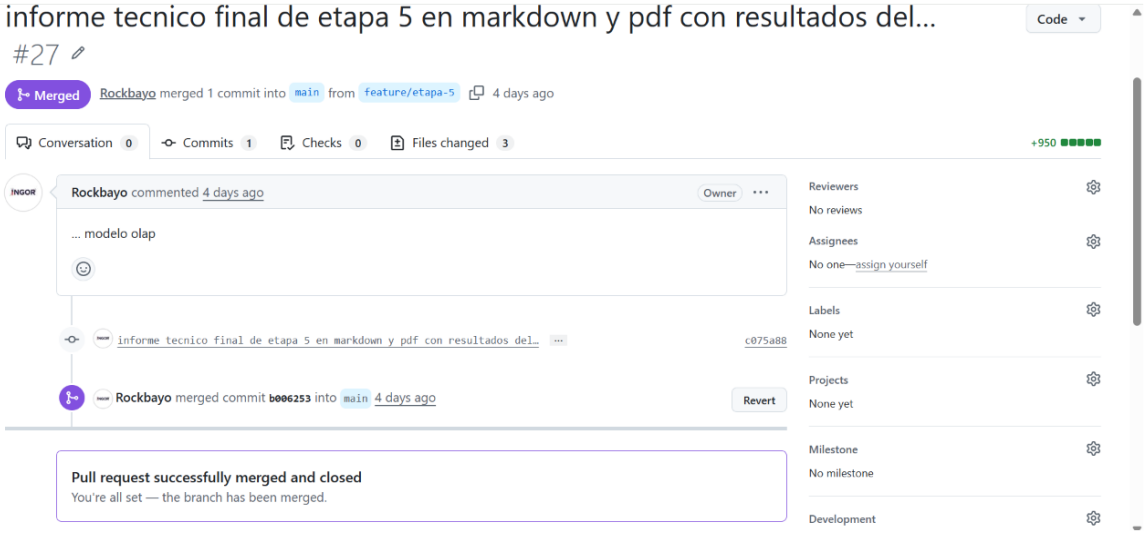


Figura 14. *Pull request #27 (informe técnico final de la Etapa 5), fusionado a main por Rockbayo.*

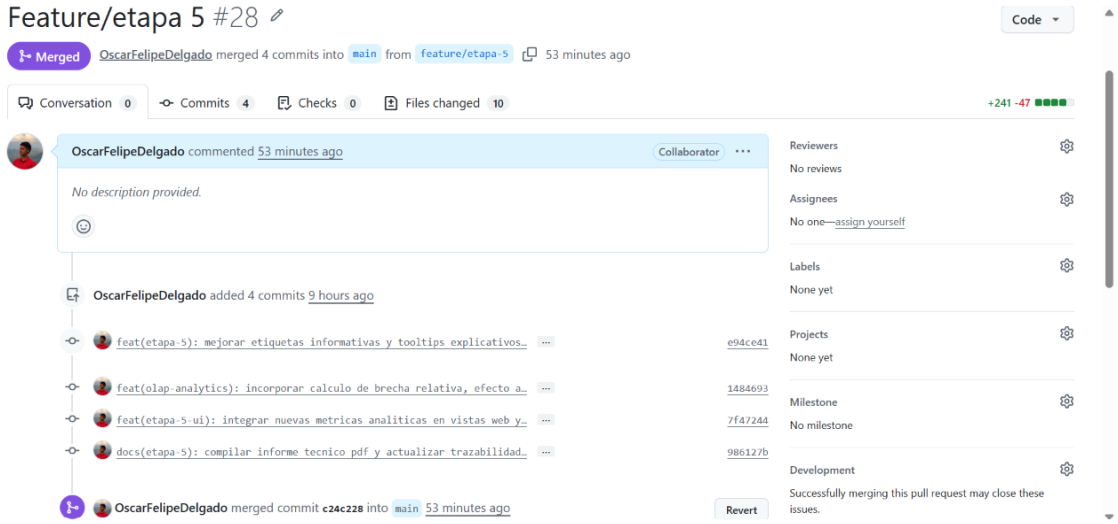


Figura 15. *Pull request #28 (Feature/etapa 5), con 4 commits de Oscar Felipe Delgado fusionados a main.*