UNIVERSIDAD DE CUNDINAMARCA

FACULTAD DE INGENIERÍA · PROGRAMA DE INGENIERÍA DE SISTEMAS
ESPACIO ACADÉMICO: MINERÍA DE DATOS · SEMESTRE 2026-II

INFORME TÉCNICO · ETAPA 5

ANÁLISIS MULTIDIMENSIONAL / MODELO ESTRELLA OLAP

Efecto de la Brecha Digital sobre el Rendimiento Académico en Saber 11 (2019-1 a 2025-2)

Proyecto:	EduMetricsCO — Plataforma Analítica Multidimensional
Población:	4,541,655 Evaluaciones Saber 11 (14 Semestres Académicos)
Integrantes:	Oscar Giovanni Robayo Olaya & Oscar Felipe Delgado
Docente:	Evaluador de Minería de Datos
Repositorio GitHub:	https://github.com/Rockbayo/MD_Proyecto_Educacion
Rama Oficial:	feature/etapa-5
Aplicación Web:	http://127.0.0.1:5000/etapa5
Fecha:	Noviembre de 2026

1. Resumen Ejecutivo y Continuidad del Proyecto

El presente informe documenta el desarrollo e implementación del **modelo multidimensional (esquema estrella)** para el proyecto EduMetricsCO. Se mantiene la continuidad estricta sobre el conjunto de datos de las etapas previas: **4,541,655 registros reales** correspondientes a 14 periodos continuos de las pruebas Saber 11 (2019-1 a 2025-2). La investigación profundiza en los 12 conocimientos evidentes de la Etapa 4 mediante consultas analíticas relacionales en SQLite y cuatro vistas interactivas en Flask provistas de operaciones OLAP (Drill-down, Roll-up, Slice, Dice y Pivot).

Unidad de Análisis vs. Granularidad: La unidad de análisis corresponde a la evaluación individual de un estudiante. La granularidad de la tabla de hechos (fact_resultados_saber11) representa una celda multidimensional agregada que consolida a los evaluados con idéntica combinación de dimensiones (Tiempo × Geografía × Perfil Digital × Socioeconómico), garantizando aditividad matemática perfecta.

2. Formulación de las Cuatro Preguntas de Investigación

Vista / Pregunta	Dimensiones y Jerarquías	Medidas Clave
P1 (Territorial): ¿Cómo varía la penalización por exclusión digital sobre el puntaje global y matemáticas al desagregar desde regiones macro hacia departamentos y zonas?	dim_geografia (Región → Depto → Zona) dim_acceso_digital (Perfil TIC)	Promedio Global, Promedio Matemáticas, Brecha Digital (pts)
P2 (Temporal): ¿Cómo varió la brecha público-privada a través de las etapas Pre-Pandemia, Pandemia y Post-Pandemia al controlar por tenencia de computador?	dim_tiempo (Etapa → Año → Periodo) dim_geografia (Sector Oficial/Privado) dim_acceso_digital (PC)	Promedio Global por sector, Diferencial de hardware, Brecha Privado-Público
P3 (Capital Cultural): ¿En qué magnitud el computador en el hogar mitiga el bajo nivel educativo parental sobre lectura crítica, matemáticas y ciencias?	dim_socioeconomica (Escolaridad, Estrato) dim_acceso_digital (PC)	Promedios disciplinares (Lectura, Matemáticas, Ciencias), Ventaja mitigadora
P4 (Hábitos TIC): ¿Cómo se relaciona la intensidad horaria de internet con el nivel B1/B+ de inglés frente al riesgo de caer en puntaje crítico (< 220)?	dim_acceso_digital (Horas dedicación) dim_geografia (Zona, Sector)	Promedio Inglés, % Bilingüe (B1/B+), % Riesgo Crítico (<220 pts)

3. Arquitectura del Modelo Estrella y Diccionario

El modelo se almacena en SQLite (data/processed/edumetrics_olap.db, 72.33 MB), optimizado con índices compuestos en claves foráneas. Estructura 1 tabla de hechos y 4 dimensiones:

Tabla	Rol / Tipo	Claves	Atributos Principales y Granularidad
fact_resultados_saber11	Hechos	PK id_hecho FKs: id_tiempo, id_geografia, id_digital, id_socioeconomico	717,225 celdas agregadas. Medidas: num_evaluados, suma_punt_global, suma_matematicas, suma_ingles, eval_riesgo_bajo, eval_ingles_bilingue.
dim_tiempo	Dimensión	PK id_tiempo	14 registros. periodo (20191-20252), anio, semestre_num, semestre_etiqueta, etapa_pandemia (Pre, Pandemia, Post).
dim_geografia	Dimensión	PK id_geografia	198 combinaciones. region_dane (8 macro-regiones), cole_depto_ubicacion (33 entidades), cole_area_ubicacion, cole_naturaleza, cole_calendario.

dim_acceso_digital	Dimensión	PK id_digital	54 combinaciones. perfil_acceso_tic (Pleno, Movil, Offline, Exclusion), fami_tieneinternet, fami_tienecomputador, estu_dedicacioninternet.
dim_socioeconomica	Dimensión	PK id_socioeconomico	220 combinaciones. grupo_estrato (Bajo, Medio, Alto), fami_estratovivienda, grupo_educacion_padre (Primaria a Posgrado), estu_genero.

4. Comprobaciones de Calidad y Validación del Modelo

Se ejecutó el protocolo de verificación automática comparando la base relacional contra el archivo plano de 4.54M de registros (reporte en validacion_modelo_estrella.json):

Comprobación	Resultado CSV Origen	Resultado Modelo Estrella	Estado y Justificación
1. Volumetría e Integridad	4,541,655 evaluados	4,541,655 evaluados 0 foráneas huérfanas	**Aprobado (Diferencia: 0).** Cuadratura poblacional exacta al 100%.
2. Paridad Métrica	Puntaje Global: 252.4228 Matemáticas: 51.2312 Inglés: 50.2534	Puntaje Global: 252.4228 Matemáticas: 51.2312 Inglés: 50.2534	**Aprobado.** Tolerancia matemática absoluta (0.0000 de desviación en medidas aditivas).
3. Segmentación TIC	Con internet: 3,154,805 (260.67) Sin internet: 1,386,850 (233.66)	Con internet: 3,154,805 (260.67) Sin internet: 1,386,850 (233.66)	**Aprobado.** Concordancia idéntica en agregaciones bivariadas y segmentación de conectividad.

5. Evidencias de las Cinco Operaciones OLAP

5.1. Operación Drill-Down & Roll-Up (Jerarquía Territorial · Vista 1)

Permite alternar entre la visión macro-regional (Roll-up a 8 regiones DANE) y la exploración departamental (Drill-down a 33 entidades y zonas).

```
SELECT g.region_dane, SUM(f.num_evaluados) AS n, ROUND(CAST(SUM(f.suma_punt_global) AS
REAL)/SUM(f.num_evaluados),2) AS prom FROM fact_resultados_saber11 f JOIN dim_geografia g ON f.id_geografia =
g.id_geografia GROUP BY g.region_dane ORDER BY prom DESC;
```

5.2. Operación Slice (Corte Temporal · Vista 2)

Aísla el subconjunto correspondiente a la etapa de pandemia (2020-2021) para estudiar el comportamiento escolar bajo confinamiento.

```
SELECT t.periodo, g.cole_naturaleza, ROUND(CAST(SUM(f.suma_punt_global) AS REAL)/SUM(f.num_evaluados),2) AS
prom FROM fact_resultados_saber11 f JOIN dim_tiempo t ON f.id_tiempo=t.id_tiempo JOIN dim_geografia g ON
f.id_geografia=g.id_geografia WHERE t.etapa_pandemia LIKE '2. Pandemia%' GROUP BY t.periodo,
g.cole_naturaleza;
```

5.3. Operación Dice (Subcubo Multivariable · Vista 2 y 4)

Intersecta simultáneamente tres dimensiones: Sector Oficial/Privado × Tenencia de Computador × Etapa Epidemiológica.

```
SELECT t.etapa_pandemia, d.fami_tienecomputador, g.cole_naturaleza, ROUND(CAST(SUM(f.suma_punt_global) AS
REAL)/SUM(f.num_evaluados),2) FROM fact_resultados_saber11 f JOIN dim_tiempo t ON f.id_tiempo=t.id_tiempo
JOIN dim_geografia g ON f.id_geografia=g.id_geografia JOIN dim_acceso_digital d ON f.id_digital=d.id_digital
GROUP BY t.etapa_pandemia, d.fami_tienecomputador, g.cole_naturaleza;
```

5.4. Operación Pivot (Rotación de Ejes Matriciales · Vista 3)

Rota los ejes relacionales ubicando el nivel educativo parental en filas y la presencia de computador en columnas para evaluar matrices de cruce.

```
SELECT s.grupo_educacion_padre, d.fami_tienecomputador, SUM(f.num_evaluados),
ROUND(CAST(SUM(f.suma_punt_global) AS REAL)/SUM(f.num_evaluados),2) FROM fact_resultados_saber11 f JOIN
dim_socioeconomica s ON f.id_socioeconomico=s.id_socioeconomico JOIN dim_acceso_digital d ON
f.id_digital=d.id_digital GROUP BY s.grupo_educacion_padre, d.fami_tienecomputador;
```

6. Documentación de los Ocho Conocimientos Multidimensionales

Cada conocimiento responde a una necesidad analítica específica y se estructura bajo los 8 elementos requeridos:

CM 1.1: Gradiente Territorial de Exclusión Digital en el Caribe	
Pregunta:	¿Cuál es la magnitud de la brecha digital al desagregar por macro-regiones DANE?
Dimensiones / Medidas:	dim_geografia.region_dane, dim_acceso_digital.perfil_acceso_tic, punt_global
Procedimiento OLAP:	Roll-up regional y cálculo de brecha entre Acceso Pleno y Exclusión Absoluta.
Evidencia Numérica:	Matriz interactiva Vista 1 (N = 931,451 en Región Caribe).
Hallazgo con Cifras:	La brecha digital más severa ocurre en la Región Caribe con 42.24 puntos de penalización (264.12 pts pleno vs 221.88 pts exclusión), frente a 31.15 pts en Bogotá.
Interpretación vs. Evidente:	Supera la simple observación urbano-rural al evidenciar que la falta de conectividad profundiza las desigualdades regionales históricas.
Utilidad para Decisiones:	Focalización de redes dorsales de fibra óptica y subsidios de conexión fija en departamentos costeros.
Limitación Metodológica:	El indicador no mide ancho de banda efectivo ni estabilidad del fluido eléctrico.

CM 1.2: Penalización en Matemáticas en Sedes Rurales Periféricas

Pregunta:	¿Cómo castiga la falta de conectividad en matemáticas en departamentos periféricos?
Dimensiones / Medidas:	dim_geografia (Depto, Zona), dim_acceso_digital, punt_matematicas
Procedimiento OLAP:	Drill-down a nivel departamental rural cruzado con perfiles de acceso.
Evidencia Numérica:	Gráfica territorial y matriz de desempeño en Vista 1.
Hallazgo con Cifras:	En Chocó, La Guajira y Magdalena, el promedio rural en matemáticas sin TIC es de 39.42 pts, ubicando al 87% en nivel insuficiente (Nivel 1).
Interpretación vs. Evidente:	Demuestra que más de 12 puntos del rezago rural en ciencias exactas son atribuibles a la ausencia de recursos digitales.
Utilidad para Decisiones:	Dotación de laboratorios computacionales con simuladores matemáticos offline.
Limitación Metodológica:	No aísla el impacto de la formación pedagógica docente.

CM 2.1: Ampliación Asimétrica de la Brecha Público-Privada en Pandemia	
Pregunta:	¿Cómo evolucionó la distancia entre colegios oficiales y no oficiales durante el COVID-19?
Dimensiones / Medidas:	dim_tiempo.etapa_pandemia, dim_geografia.cole_naturaleza, punt_global
Procedimiento OLAP:	Slice en ventana epidemiológica (2020-2021) frente a Pre-pandemia (2019).
Evidencia Numérica:	Serie de tiempo en Vista 2 (4.54M evaluados en 14 periodos).
Hallazgo con Cifras:	La brecha privado-oficial se amplió en 5.82 puntos netos durante el confinamiento, escalando de 32.40 pts en 2019 a 38.22 pts en 2021-2.
Interpretación vs. Evidente:	La caída académica fue casi exclusivamente absorbida por los colegios oficiales de calendario A.
Utilidad para Decisiones:	Priorización presupuestal para planes de tutorías y nivelación en colegios distritales y municipales.
Limitación Metodológica:	No se cuenta con la fecha exacta de reapertura presencial por municipio.

CM 2.2: Efecto Amortiguador del Computador en el Sector Oficial	
Pregunta:	¿Qué papel jugó la disponibilidad de PC en los hogares oficiales durante el confinamiento?
Dimensiones / Medidas:	dim_tiempo.etapa_pandemia, dim_acceso_digital.fami_tienecomputador, punt_global
Procedimiento OLAP:	Dice combinando sector público, hardware y periodos de confinamiento.
Evidencia Numérica:	Matriz de hardware por etapas en Vista 2.
Hallazgo con Cifras:	Los estudiantes oficiales con computador alcanzaron 261.15 pts en pandemia, superando en 27.15 pts a quienes carecían del equipo (234.00 pts).
Interpretación vs. Evidente:	El computador evitó el colapso del aprendizaje remoto en estudiantes de bajos recursos.
Utilidad para Decisiones:	Sustentación de compras públicas masivas de dispositivos para estudiantes vulnerables.
Limitación Metodológica:	Se desconoce el grado de compartición del dispositivo con hermanos o padres.

CM 3.1: Efecto Mitigador del Computador sobre el Rezago Parental	
Pregunta:	¿Puede el computador compensar la baja escolaridad de los padres?
Dimensiones / Medidas:	dim_socioeconomica.grupo_educacion_padre, dim_acceso_digital, punt_global
Procedimiento OLAP:	Operación Pivot disponiendo educación en filas y PC en columnas.
Evidencia Numérica:	Matriz pivote Vista 3 (N = 824,000 padres sin escolaridad o primaria incompleta).

Hallazgo con Cifras:	Un estudiante con padres sin escolaridad pero con PC obtiene 244.18 pts, superando en 28.52 pts a su par sin computador (215.66 pts).
Interpretación vs. Evidente:	El equipamiento tecnológico actúa como puente que atenúa el determinismo sociocultural del hogar.
Utilidad para Decisiones:	Inclusión de dotación tecnológica como pilar de política social para romper trampas de pobreza intergeneracional.
Limitación Metodológica:	Tasa de no respuesta del 19.99% en el autorreporte de educación de los padres.

CM 3.2: Mayor Sensibilidad de la Lectura Crítica ante el Equipamiento TIC	
Pregunta:	¿Qué competencia disciplinar es más sensible a la presencia del computador?
Dimensiones / Medidas:	dim_socioeconomica, punt_lectura_critica, punt_matematicas, punt_c_naturales
Procedimiento OLAP:	Agregación multidimensional de puntajes por área bajo estrato bajo.
Evidencia Numérica:	Radar de competencias en Vista 3.
Hallazgo con Cifras:	La ventaja del PC en estratos 1 y 2 es de 6.81 puntos en Lectura Crítica, frente a 4.92 en Ciencias Naturales y 5.12 en Matemáticas.
Interpretación vs. Evidente:	El acceso a textos electrónicos, interfaces interactivas y bibliotecas virtuales impacta preferencialmente la comprensión lectora.
Utilidad para Decisiones:	Despliegue de plataformas de lectura comprensiva guiada en tablets escolares.
Limitación Metodológica:	La prueba mide aptitud psicométrica formal y no hábitos lectores extracurriculares.

CM 4.1: Salto Exponencial al Bilingüismo por Intensidad de Navegación	
Pregunta:	¿Cuál es el vínculo entre las horas de navegación y el nivel de inglés B1/B+?
Dimensiones / Medidas:	dim_acceso_digital.estu_dedicacioninternet, desemp_ingles, punt_ingles
Procedimiento OLAP:	Drill-down por tramos horarios y cálculo de proporción de bilingüismo.
Evidencia Numérica:	Gráfico de barras y línea en Vista 4.
Hallazgo con Cifras:	Navegar más de 3 horas diarias multiplica por 6 la probabilidad de ser bilingüe: 17.91% alcanza B1/B+ (54.0 pts) vs 2.94% sin conexión (43.47 pts).
Interpretación vs. Evidente:	El aprendizaje de un segundo idioma se beneficia del consumo multimedia y la inmersión informal en la red.
Utilidad para Decisiones:	Promover el autoaprendizaje y aplicaciones de idiomas libres de consumo de datos para bachilleres.
Limitación Metodológica:	No se diferencia el uso recreativo en redes sociales del uso educativo formal.

CM 4.2: La Desconexión Total como Predictor de Riesgo Crítico	
Pregunta:	¿En qué medida no navegar en internet dispara el riesgo académico (<220 pts)?
Dimensiones / Medidas:	dim_acceso_digital.estu_dedicacioninternet, eval_riesgo_bajo, fami_estratovivienda
Procedimiento OLAP:	Operación Dice calculando la tasa de evaluados con puntaje inferior a 220.
Evidencia Numérica:	Gráfico de dona y matriz de riesgo en Vista 4.
Hallazgo con Cifras:	El 53.83% de los estudiantes sin internet cae en riesgo crítico (< 220 pts), tasa que se reduce a 22.76% en quienes navegan de 1 a 3 horas.
Interpretación vs. Evidente:	La exclusión digital actúa como un factor de vulnerabilidad crítica en la evaluación oficial.

Utilidad para Decisiones:	Alertas tempranas automáticas para focalizar tutorías en bachilleres sin conectividad domiciliaria.
Limitación Metodológica:	Causalidad compartida con otras privaciones materiales del hogar.

7. Limitaciones y Decisiones de Política Educativa

Dimensión / Vista	Limitación Metodológica	Decisión Sustentada en Cifras
Vista 1 (Territorial)	No se dispone del costo del servicio de internet ni de la velocidad en megabits por municipio.	**Conectividad Diferencial:** Priorizar subsidios de fibra óptica en 140 municipios del Caribe y Pacífico con brecha superior a 40 puntos.
Vista 2 (Temporal)	Falta de fecha exacta de reapertura física de sedes escolares durante el año lectivo 2021.	**Fondo de Resiliencia Tecnológica:** Asignar terminales portátiles al 100% de colegios oficiales para mitigar futuras contingencias.
Vista 3 (Capital Cultural)	Tasa de no respuesta del 19.99% en educación de los padres que requiere tipificación explícita.	**Alfabetización Familiar:** Acompañar la entrega de dispositivos escolares con talleres de competencias digitales para adultos en estrato 1.
Vista 4 (Hábitos TIC)	El instrumento no registra el uso pedagógico específico durante las horas de conexión.	**Ecosistemas de Inmersión:** Disponer plataformas gratuitas de aprendizaje de inglés sin costo de navegación móvil para bachilleres.

8. Conclusiones y Trazabilidad en GitHub

Conclusiones del Estudio:
1. **Viabilidad del Modelo Estrella:** El esquema implementado en SQLite comprime 4.54M de registros en 72 MB y entrega respuestas en menos de 30 ms para cubos analíticos complejos.
2. **El Factor Habilitador de la Tecnología:** La tenencia de computador en el hogar atenúa en más de 28 puntos la desventaja académica impuesta por la baja escolaridad parental.
3. **Severidad de la Brecha Periférica:** La brecha digital en la Región Caribe (42.24 pts) casi duplica el rezago geográfico promedio urbano-rural (24 pts).
4. **Vínculo con el Bilingüismo:** El acceso intensivo a internet multiplica por 6 la probabilidad de alcanzar niveles internacionales B1/B+ en inglés.

Parámetro	Valor de Verificación en Repositorio
Repositorio Oficial:	https://github.com/Rockbayo/MD_Proyecto_Educacion
Rama Activa:	feature/etapa-5 (Sincronizada con origin/feature/etapa-5)
Pull Request:	https://github.com/Rockbayo/MD_Proyecto_Educacion/pull/23
Commits de la Etapa:	Oscar Delgado (e94ce41, 1484693, 7f47244), Oscar Robayo (0efddf7, 9b0c7b6)
Script ETL Reproducible:	scripts/07_modelo_estrella_olap.py
Base de Datos Analítica:	data/processed/edumetrics_olap.db (72.33 MB SQLite)
Portal y Vistas Web:	http://127.0.0.1:5000/etapa5 (Templates pregunta1.html a pregunta4.html)